大規模データ解析入門1

- シークエンスのフィルタリング -

sequence 1 sequence 2 sequence 3 sequence 4 sequence 5 sequence 6 sequence 7 sequence 8 sequence 9 sequence 10

GGCANGTATNGCTGG GCCGAGTTTAATTGC GCCGCCCTGGCCGTA NCNAACTTCGCCCCC **ATGGATATTCAGGAA** CCGCCAAATTGTAAT **AAGNAAGGCTGAACN** TTTTTTTTTTTTTTT**GTAGCTTCAGGTGTA** AAAGCATTGCGTATG

1行 1データ

配列名

配列本体

sequence 1 GGCANGTATNGCTGG GCCGAGTTTAATTGC sequence 2 GCCGCCCTGGCCGTA sequence 3 NCNAACTTCGCCCCC sequence 4 sequence 5 ATGGATATTCAGGAA CCGCCAAATTGTAAT sequence 6 sequence 7 **AAGNAAGGCTGAACN** sequence 8 TTTTTTTTTTTTTT sequence 9 GTAGCTTCAGGTGTA sequence 10 AAAGCATTGCGTATG

タブ区切りテキスト

タブ文字

```
sequence 1 ¥t GGCANGTATNGCTGG
sequence 2 ¥t GCCGAGTTTAATTGC
sequence 3 ¥t GCCGCCCTGGCCGTA
sequence 4 ¥t NCNAACTTCGCCCCC
sequence 5 ¥t ATGGATATTCAGGAA
sequence 6 ¥t CCGCCAAATTGTAAT
sequence 7 ¥t AAGNAAGGCTGAACN
sequence 8 ¥t TTTTTTTTTTTTTT
sequence 9 ¥t GTAGCTTCAGGTGTA
sequence 10 ¥t AAAGCATTGCGTATG
```

タブ区切りテキスト

タブ文字

改行文字

```
sequence 1 ¥t GGCANGTATNGCTGG ¥n
sequence 2 ¥t GCCGAGTTTAATTGC ¥n
sequence 3 ¥t GCCGCCCTGGCCGTA ¥n
sequence 4 ¥t NCNAACTTCGCCCCC ¥n
sequence 5 ¥t ATGGATATTCAGGAA ¥n
sequence 6 ¥t CCGCCAAATTGTAAT ¥n
sequence 7 ¥t AAGNAAGGCTGAACN ¥n
sequence 8 ¥t TTTTTTTTTTTTTT ¥n
sequence 9 ¥t GTAGCTTCAGGTGTA ¥n
sequence 10 ¥t AAAGCATTGCGTATG ¥n
```

ファイルを開く

sequence 1 sequence 2 sequence 3 sequence 4 sequence 5 sequence 6 sequence 7 sequence 8 sequence 9 sequence 10 GGCANGTATNGCTGG GCCGAGTTTAATTGC GCCGCCCTGGCCGTA NCNAACTTCGCCCCC ATGGATATTCAGGAA CCGCCAAATTGTAAT **AAGNAAGGCTGAACN** TTTTTTTTTTTTTT **GTAGCTTCAGGTGTA** AAAGCATTGCGTATG

上から順番に一行ずつ読む

sequence 1 sequence 2 sequence 3 sequence 4 sequence 5 sequence 6 sequence 7 sequence 8 sequence 9 sequence 10

GGCANGTATNGCTGG GCCGAGTTTAATTGC GCCGCCCTGGCCGTA NCNAACTTCGCCCCC **ATGGATATTCAGGAA** CCGCCAAATTGTAAT **AAGNAAGGCTGAACN** TTTTTTTTTTTTTT **GTAGCTTCAGGTGTA AAAGCATTGCGTATG**

上から順番に一行ずつ読む

```
sequence 1
```

```
GGCANGTATNGCTGG
```

上から順番に一行ずつ読む

sequence 2

GCCGAGTTTAATTGC

上から順番に一行ずつ読む

sequence 3

GCCGCCCTGGCCGTA

一行を分ける

改行文字を取り除く

sequence_	_1 ¥t	GGCANGTATNGCTGG ¥n

一行を分ける

改行文字を 取り除く

sequence 1 ¥t GGCANGTATTGCTGG ¥n

今回の演習では、

- 配列の長さを調べる
- Nの数を数える
- N含有率を計算する

N含有率10%以上

sequence_1 sequence_4

BAD sequences

sequence_7
sequence_8
sequence_9

N含有率10%以上

sequence_2
sequence_3
sequence_5
sequence_6

GOOD sequences

? CGCCAAATTGTAAT

AAGNAAGGCTGAACN

ファイルを閉じる