ゲノム情報解析入門

栽培植物起原学分野

堺 俊之

自己紹介

氏名: 堺　俊之

所属: 資源生物科学科

　　栽培植物起原学研究室　准教授

専門分野: ゲノム解析, 生物統計学

　　機械学習など



研究内容: 植物のゲノム情報を解析・操作して理想的な作物を作る研究をしています。



Do not edit
How to change the design

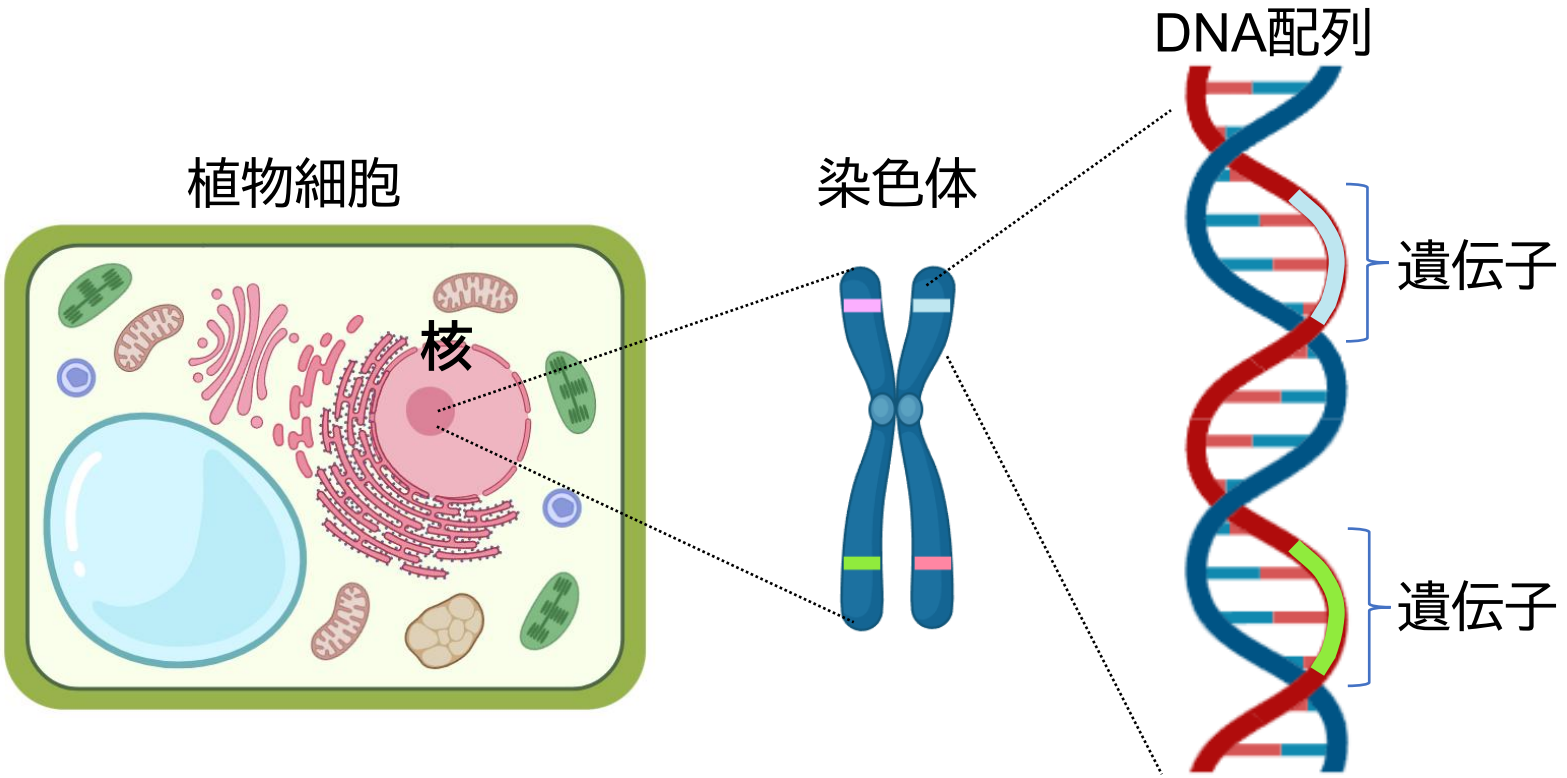


ゲノム情報とは？自分の意見を記述してください。
(QRコードか、slidoと検索して左下のアクセスコードを記入してアクセス)

The Slido app must be installed on every computer you're presenting from

slido

染色体・遺伝子



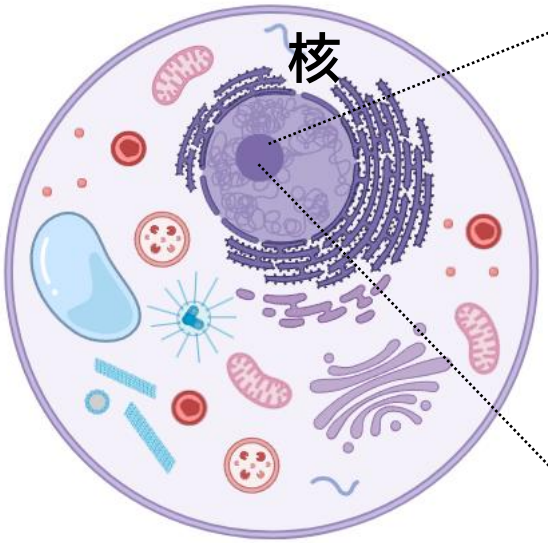
花の色や種の形等の形質を決定する遺伝子領域を含むDNA配列が、染色体として核に格納されている。

染色体・遺伝子

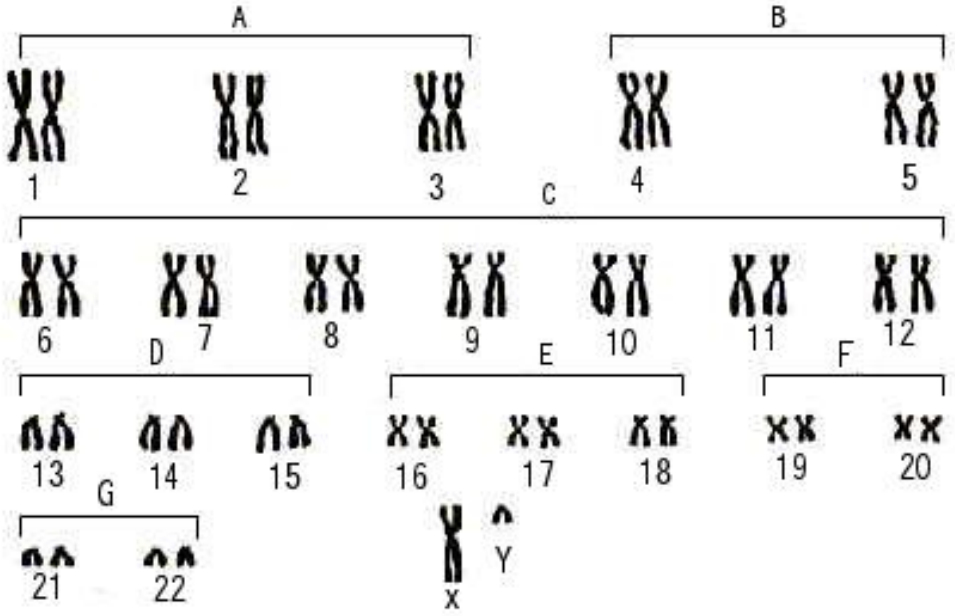
複数の染色体が核にある

ゲノム =「生物の生存に必須な最小限の染色体のセット」

ex) ヒトは23セットの染色体を2本ずつ持つ
(2n = 46)



動物細胞



https://www.tmd.ac.jp/artsci/biol/textbook/celldiv.htm

余談）ゲノムの定義は栽培植物起原学研究室創始者でもある木原均博士による

「ゲノム分析」

■ドイツの植物学者 Hans Winkler（1920）

遺伝子（gene）＋ 染色体（chromosome）

＝ ゲノム（genome）

＝「配偶子が持つ染色体のセット」

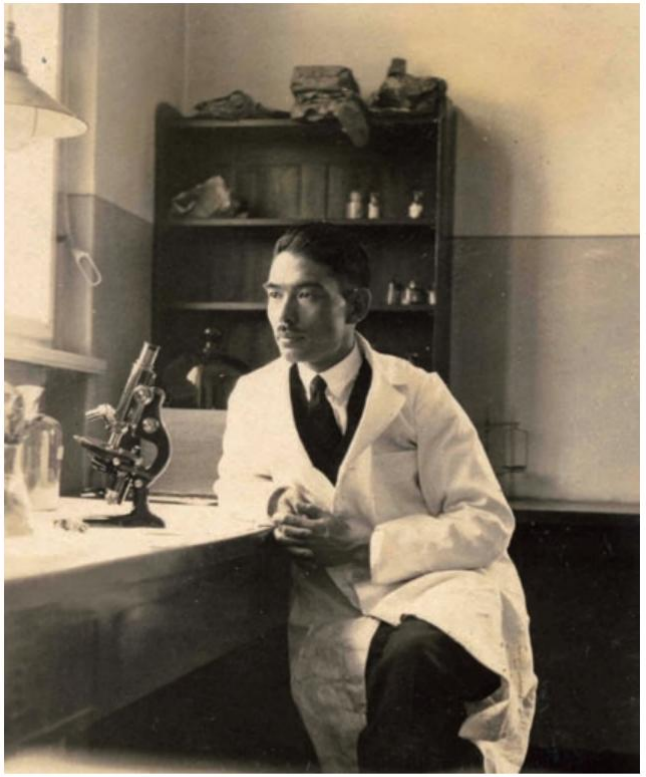


図1 ドイツ留学中（1925–27）の木原均

カール・コレンスの実験室にて （木原ゆり子氏所蔵）

生物の科学 遺伝 2019年11月発行号 Vol.73 No.6

■木原均の再定義

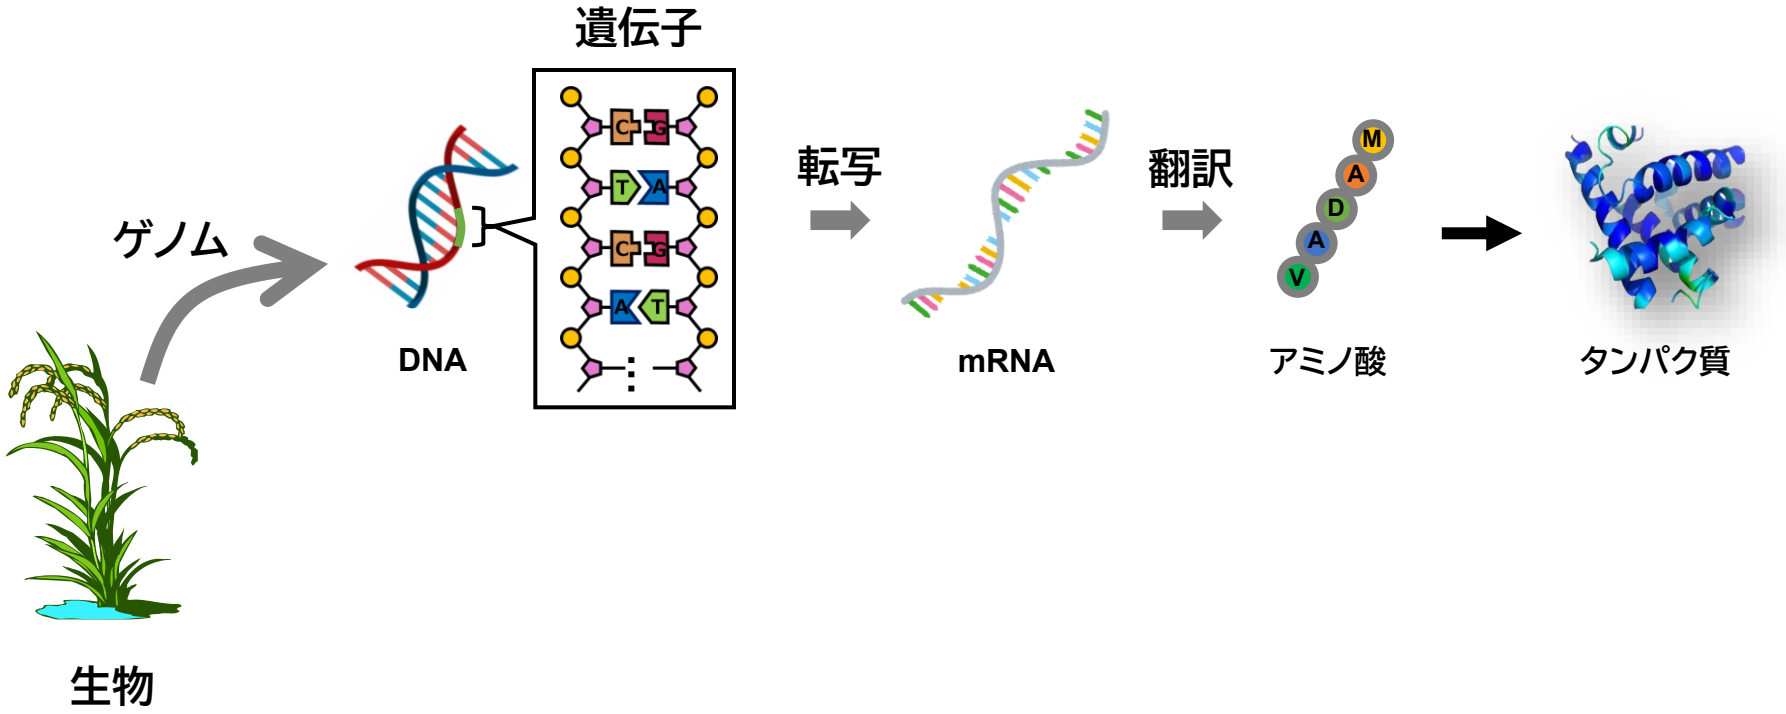
ゲノム ＝「生物の生存に必須な最小限の染色体のセット」

小麦の研究を通じて再定義

ドイツ語読み（genom）で日本に定着させる。

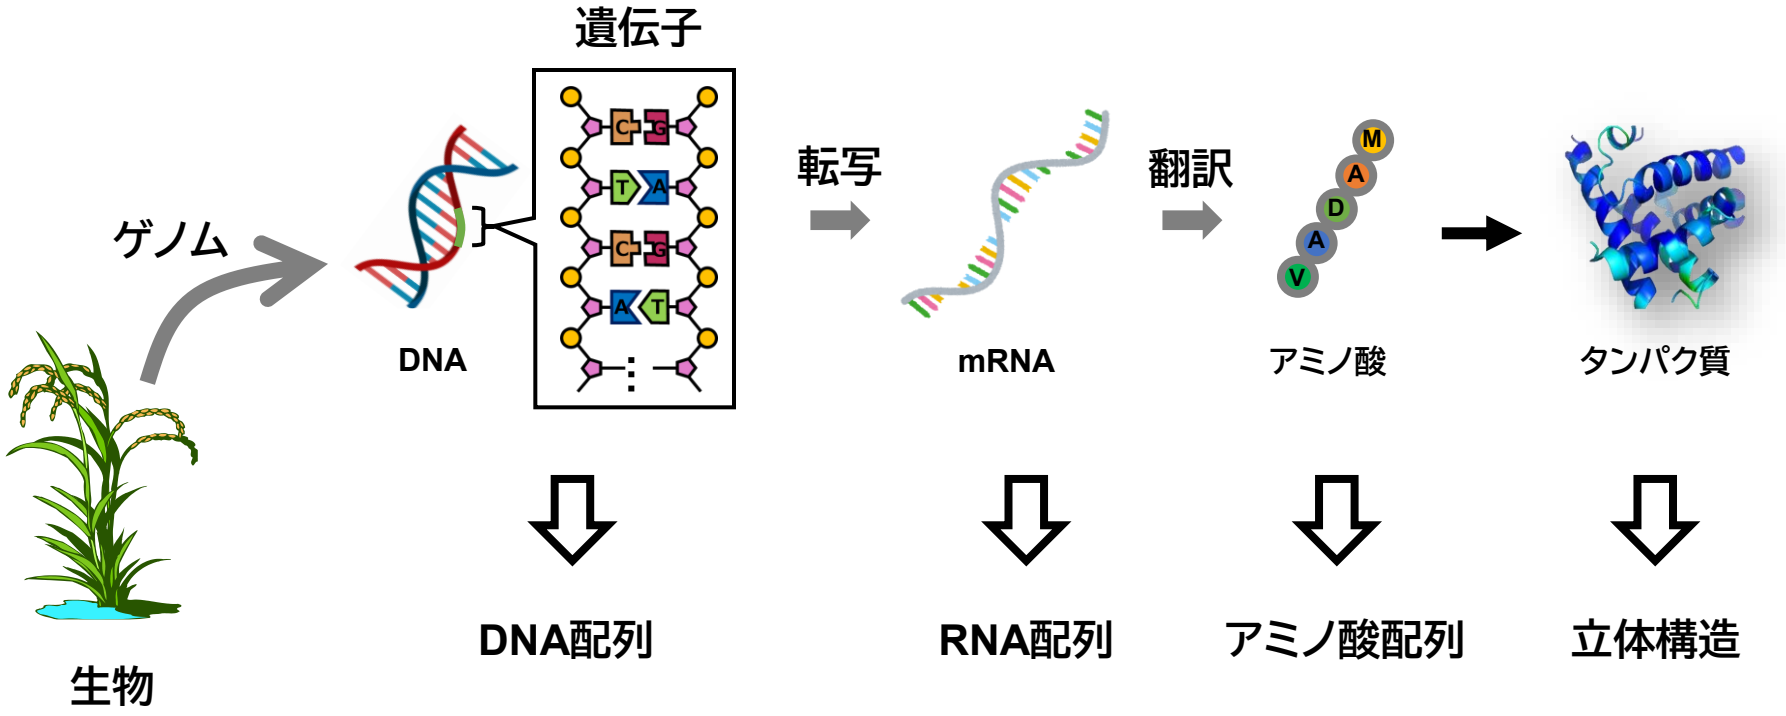
ゲノム情報とは？

分子生物学の基本原則: セントラルドグマ



ゲノム情報とは？

ゲノムは様々な情報を持つ



（参考）DNA配列，遺伝子の配列・発現などの情報の例

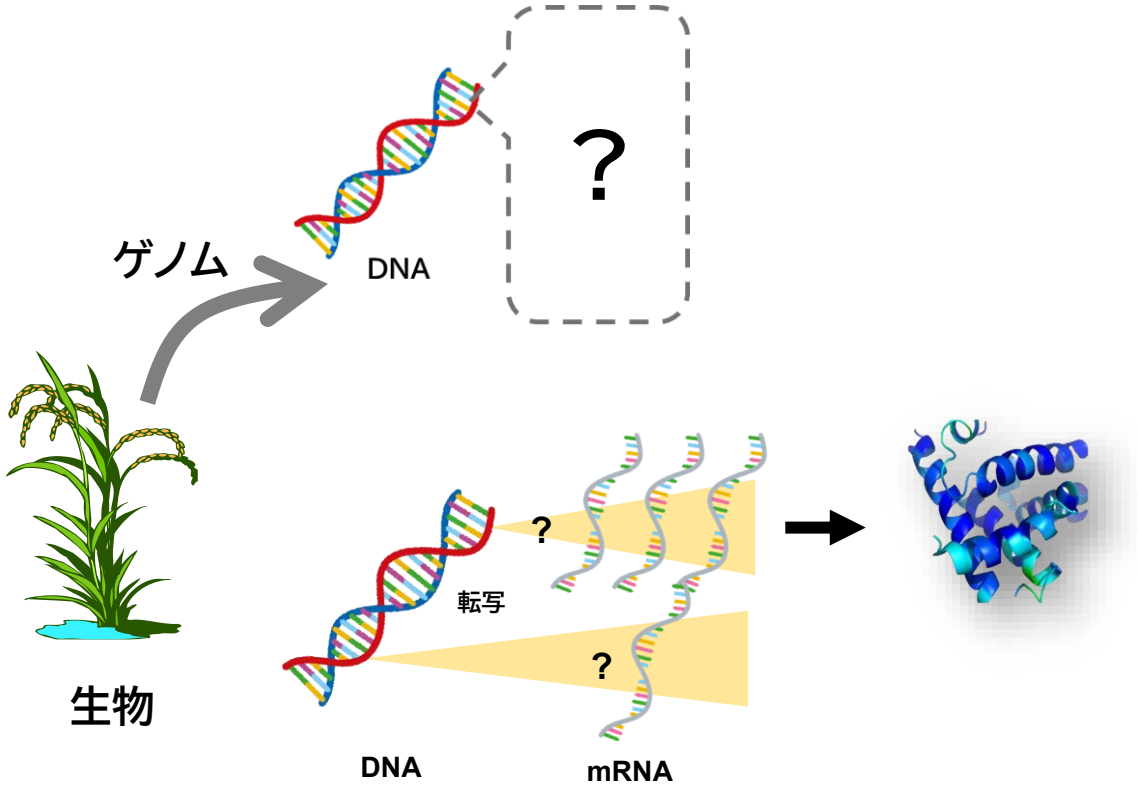
UCSC Genome (ヒトやマウスなどのデータベース)

- https://genome.ucsc.edu/

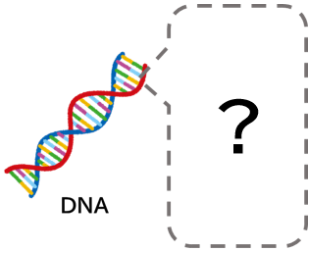
RAP-DB (イネのデータベース)

- https://rapdb.dna.naro.go.jp/index.html

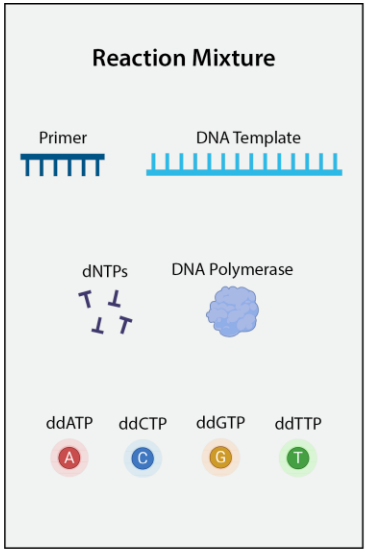
DNA配列やどんな遺伝子が転写・翻訳されているかをどう確認する？

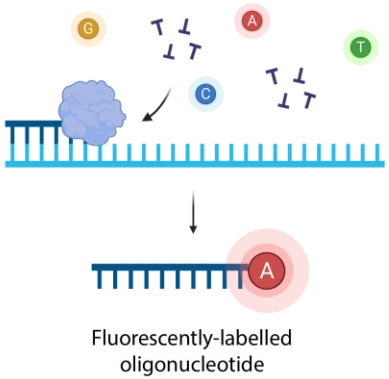


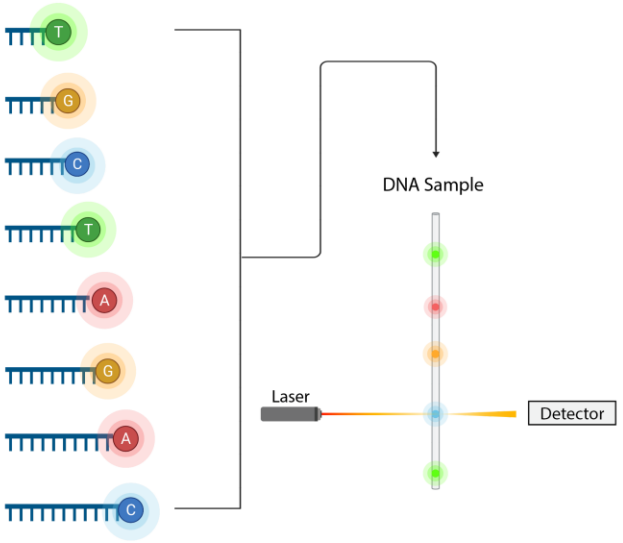
実験的にDNA配列を確認する方法の例: サンガーシーケンス

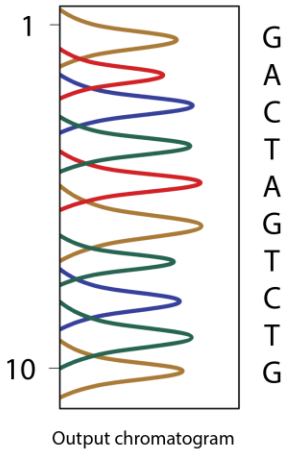


Sanger Sequencing









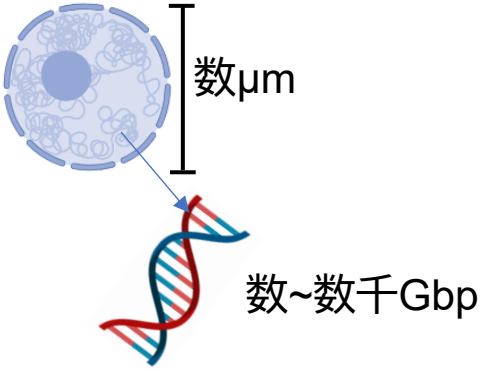
1 Chain-termination PCR using fluorescent ddNTPs

2 Size separation and sequence analysis using capillary gel electrophoresis and fluorescence detection

https://www.cosmobio.co.jp/product/detail/aat-bioquest-news-202106-3-abd.asp?entry_id=42669

~800bp程しか読めないサンガーシーケンスではゲノム解読は難しい

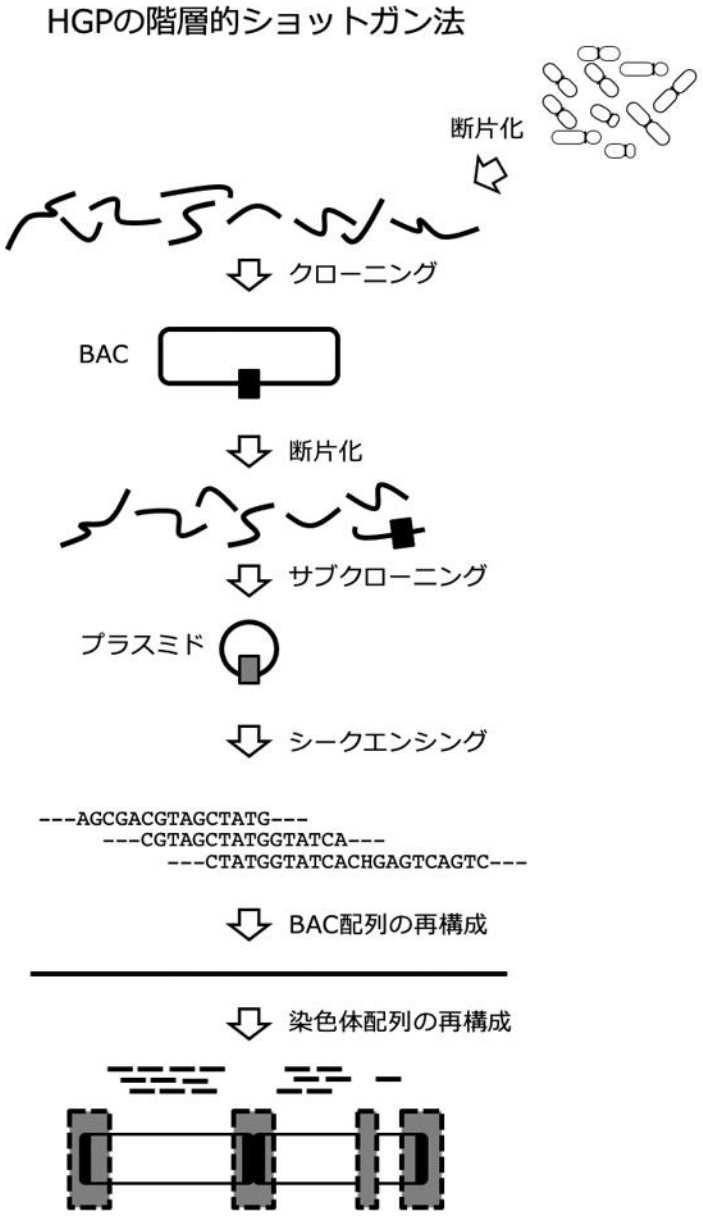
1塩基対 = 1bp (A, T, G, Cの1文字)



	生物種	ゲノムサイズ
	ヒト(*Homo sapiens*)	3.2 Gbp (32億塩基対)
	サラマンダー(*Ambystoma mexicanum*)	32 Gbp (320億塩基対)
	イネ(*Oryza sativa*)	389 Mbp (4億塩基対)
	コムギ(*Triticum aestivum*)	15.5 Gbp (150億塩基対)

(出典) https://eol.org/pages/1019571
https://arcella.nl/polychaos-dubium/

Human Genome Project: ヒトゲノム計画 (1990~2003)



アメリカ、イギリス、日本、
ドイツ、フランス、中国などが参加

染色体23本 … デカすぎる

↓

複数のブロックへ断片化

↓

大腸菌に組み込み増幅

↓

さらに断片化

↓

サンガーシーケンス(自動化)

↓

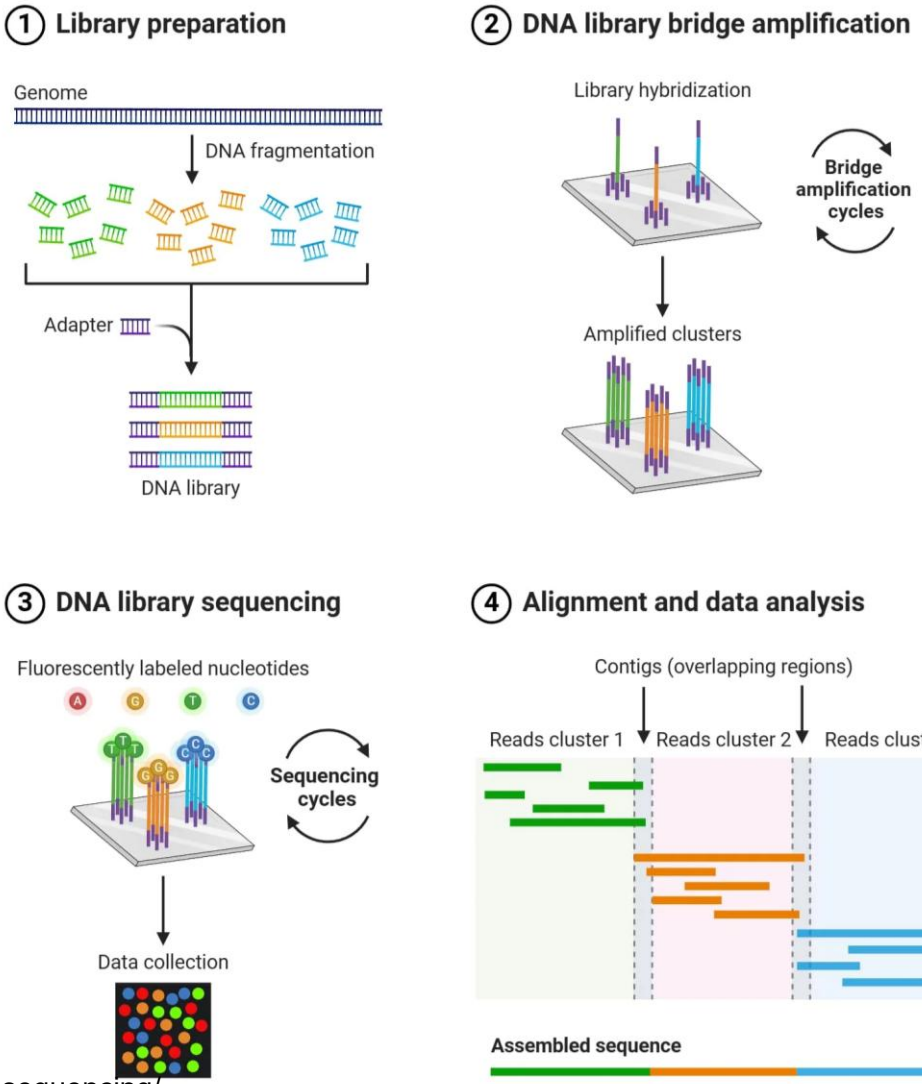
断片配列からブロックの配列を再構成

↓

ブロックの配列から染色体の配列を再構成

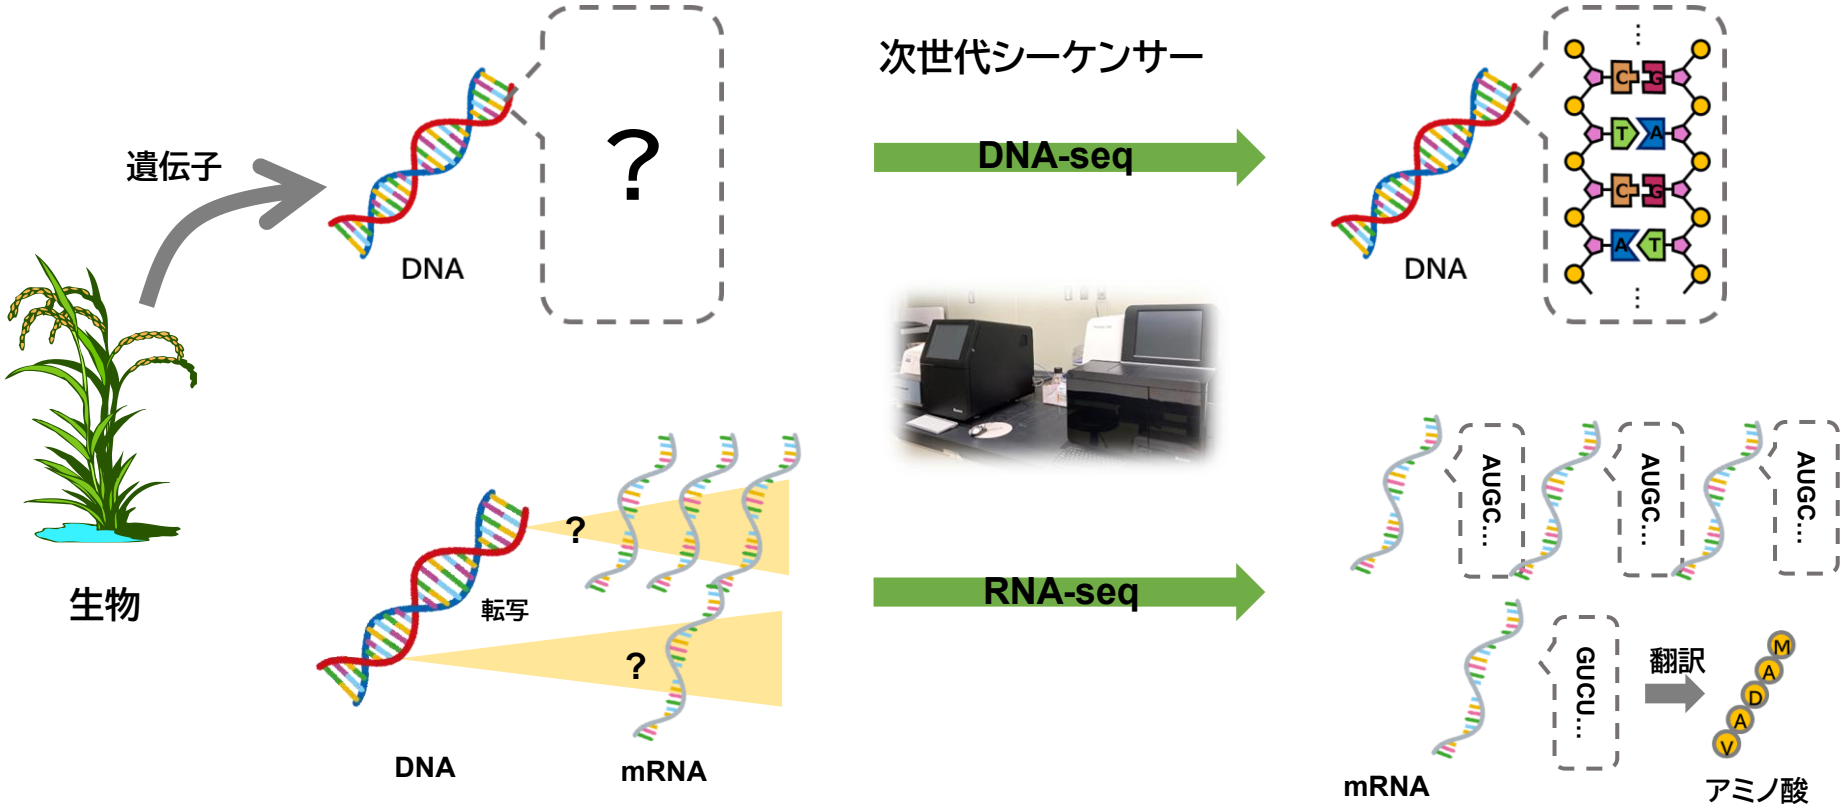
NGS (次世代シーケンサー)の登場　ショートリードシーケンス

https://www.youtube.com/watch?v=EDVKxSNdSic

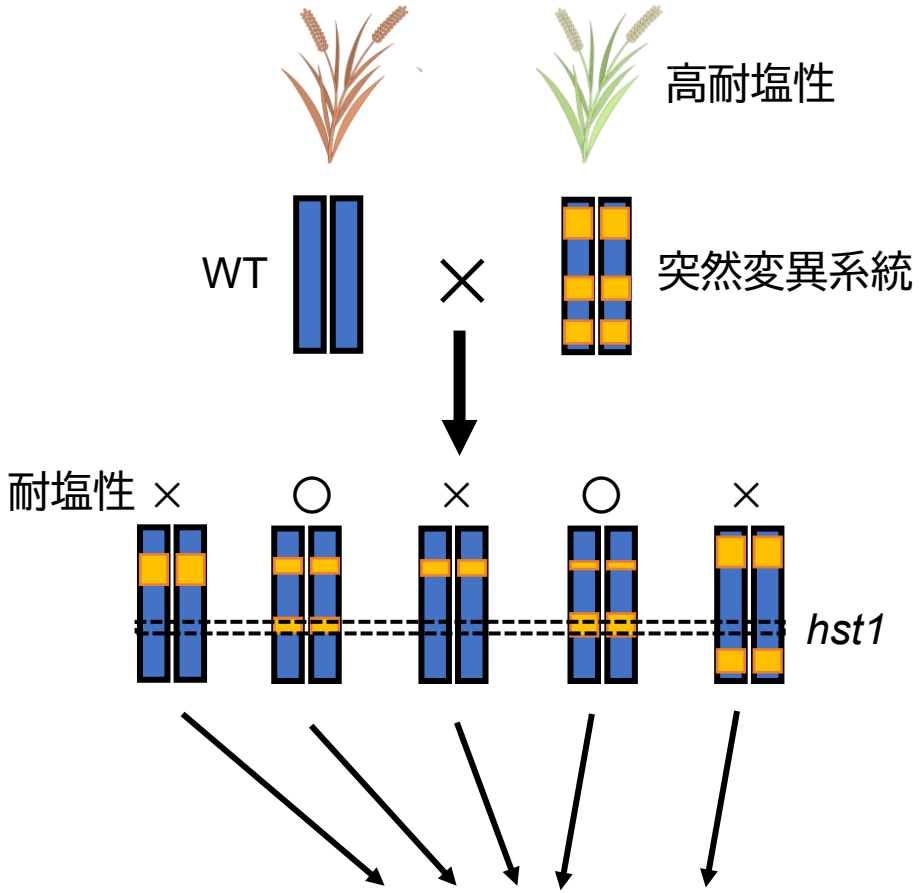


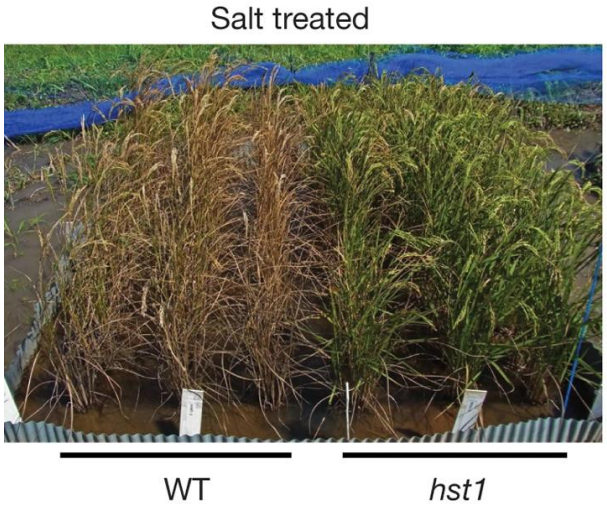
https://microbenotes.com/illumina-sequencing/

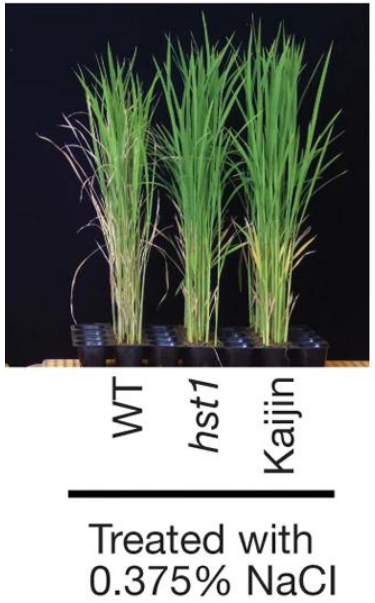
次世代シーケンサーの登場により塩基配列の解明が可能に



NGSを活用した遺伝的変異検出の活用例



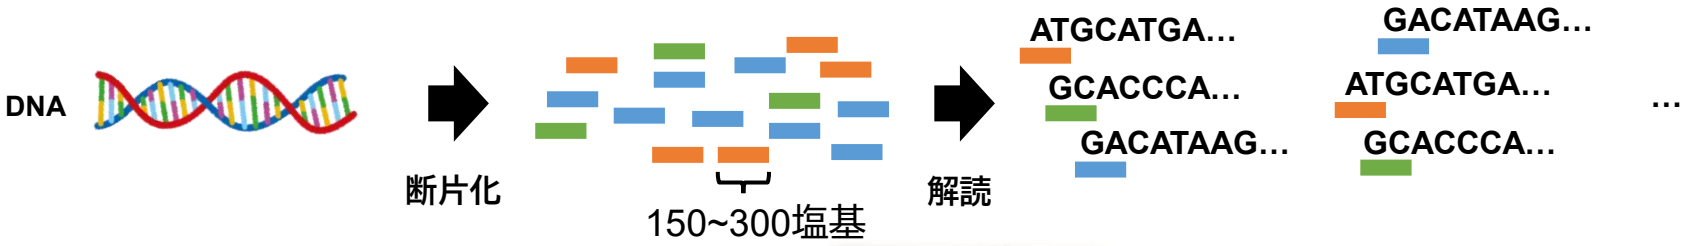




Takagi et al. 2015

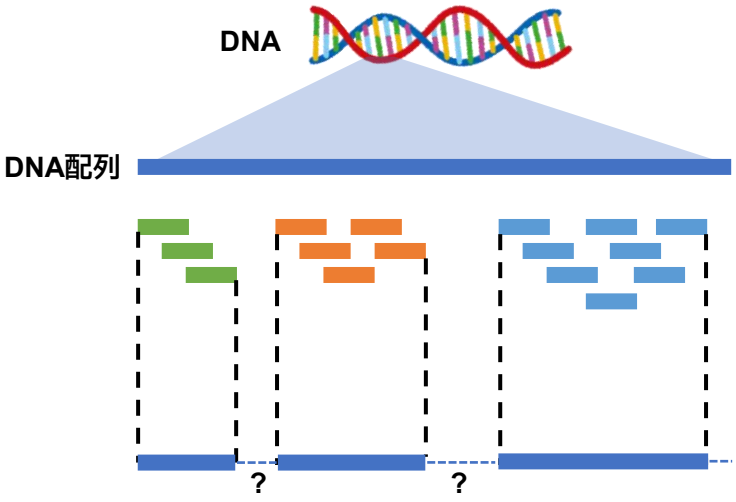
ただし、NGSでは全DNA配列を一気に読めるわけではない…

ゲノム配列を端から端まで順番に読める訳ではない。



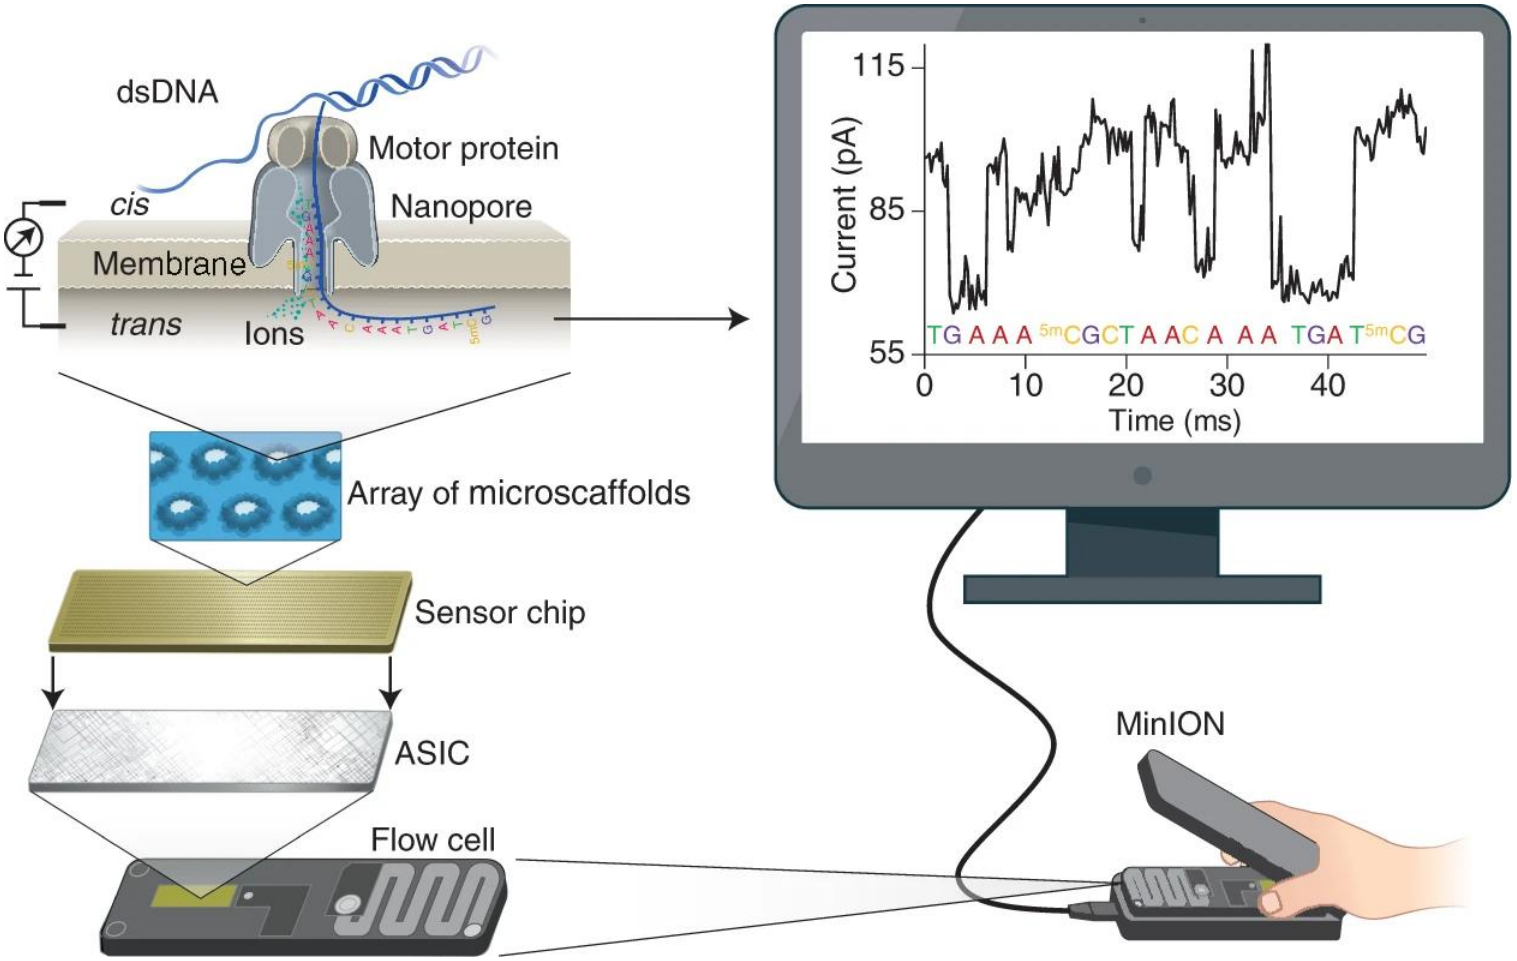


短い配列をつなぎ合わせて
元のDNA配列を復元



第3世代シーケンサーの登場　ロングリードシーケンス

https://nanoporetech.com/platform/technology



Wang et al., 2021

Do not edit
How to change the design



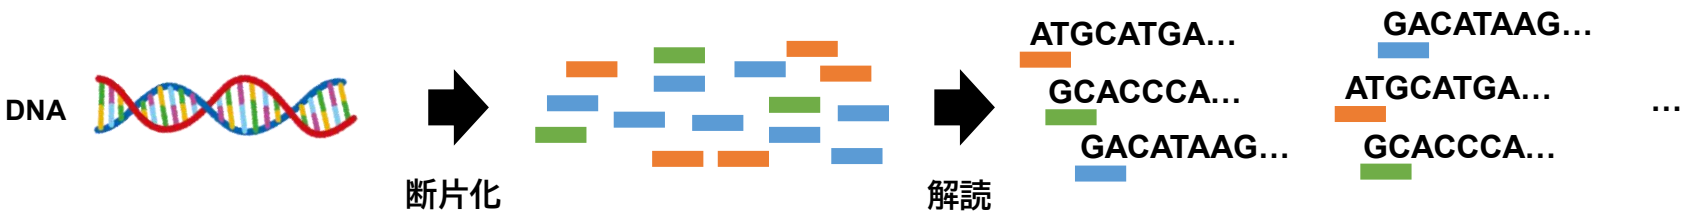
次世代シーケンサーの機械は数千万円。
では第3世代シーケンサー(ナノポアシーケンサー)の機械の価格はどのくらいか？

The Slido app must be installed on every computer you're presenting from

slido

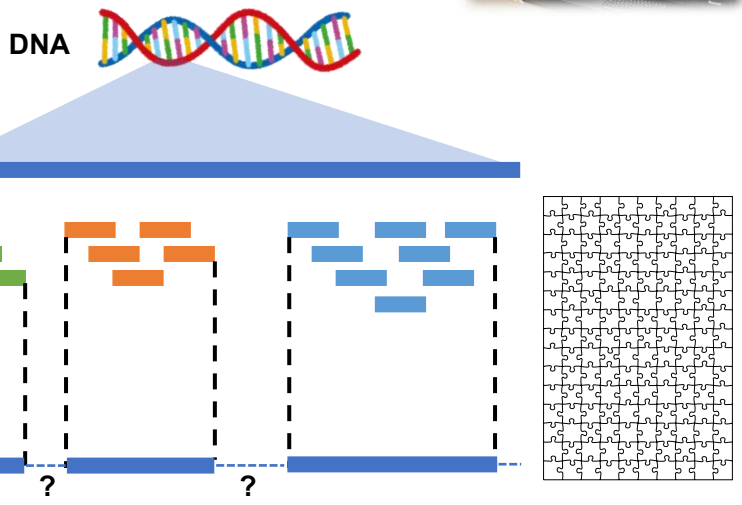
新たな技術により高精度なゲノム情報の獲得が可能な時代に

ゲノム配列を端から端まで順番に読める訳ではない。



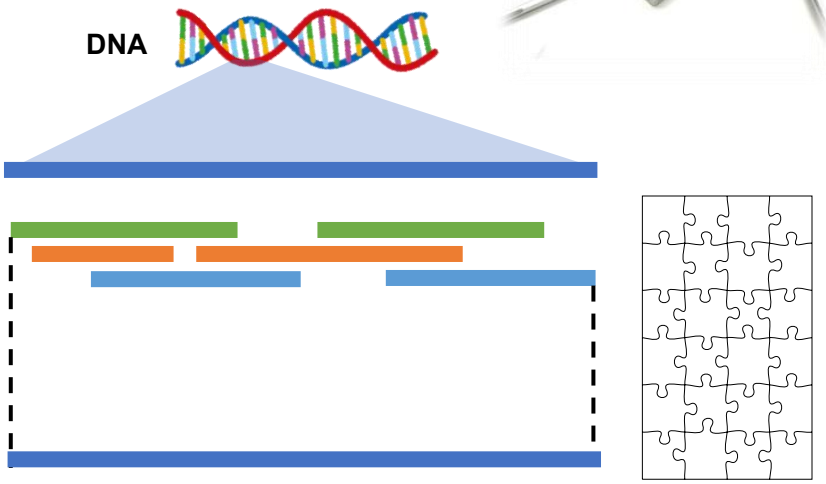
次世代シーケンサー
(150~300塩基)





第3世代シーケンサー
(10,000塩基以上)

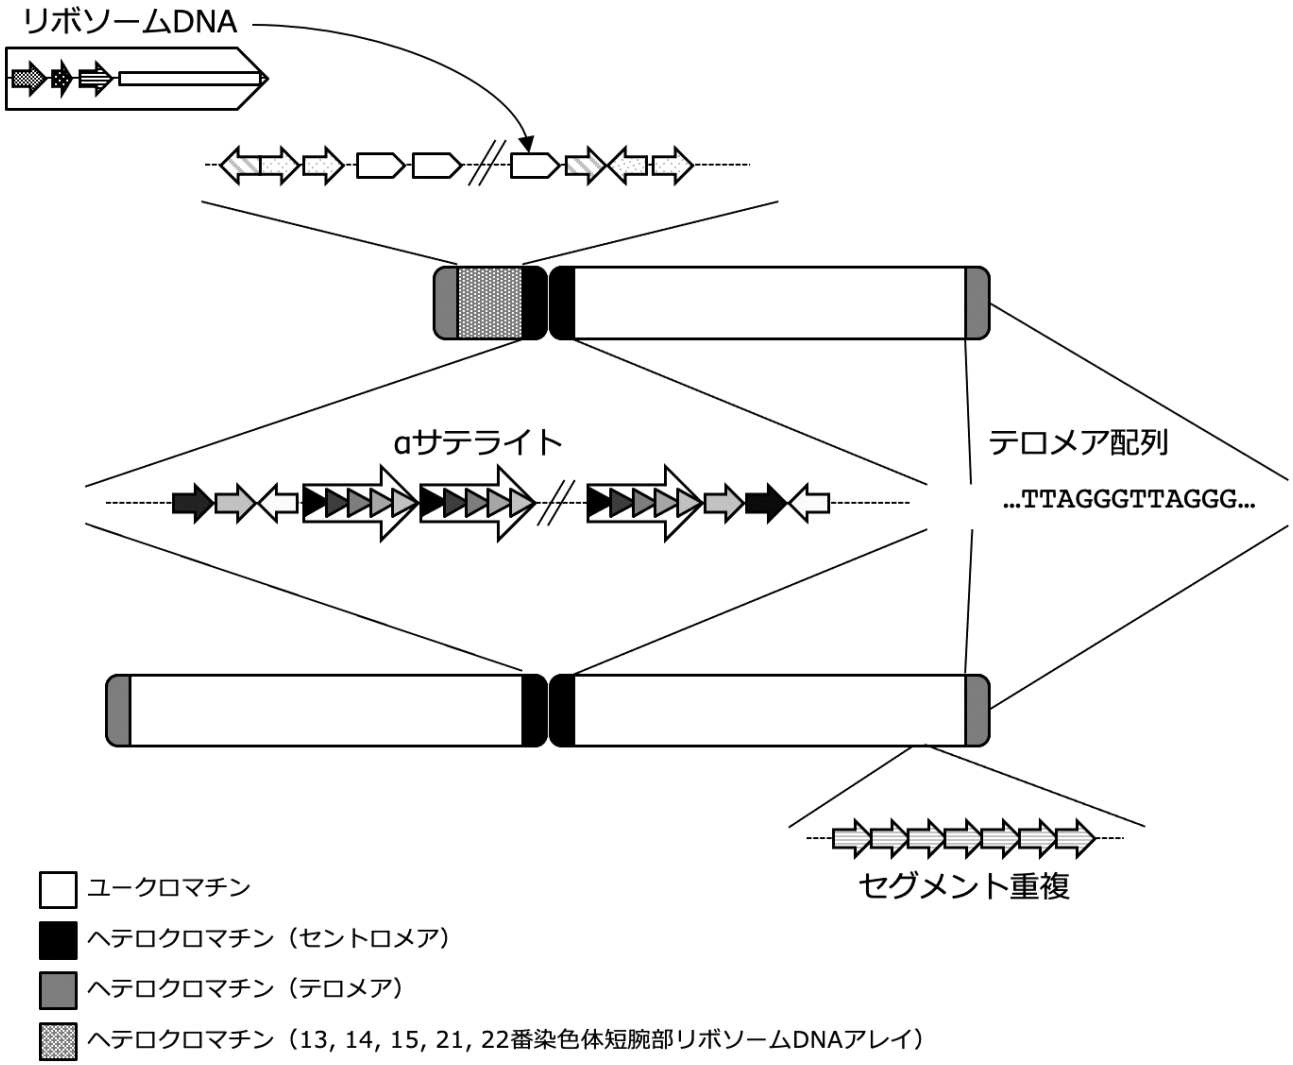




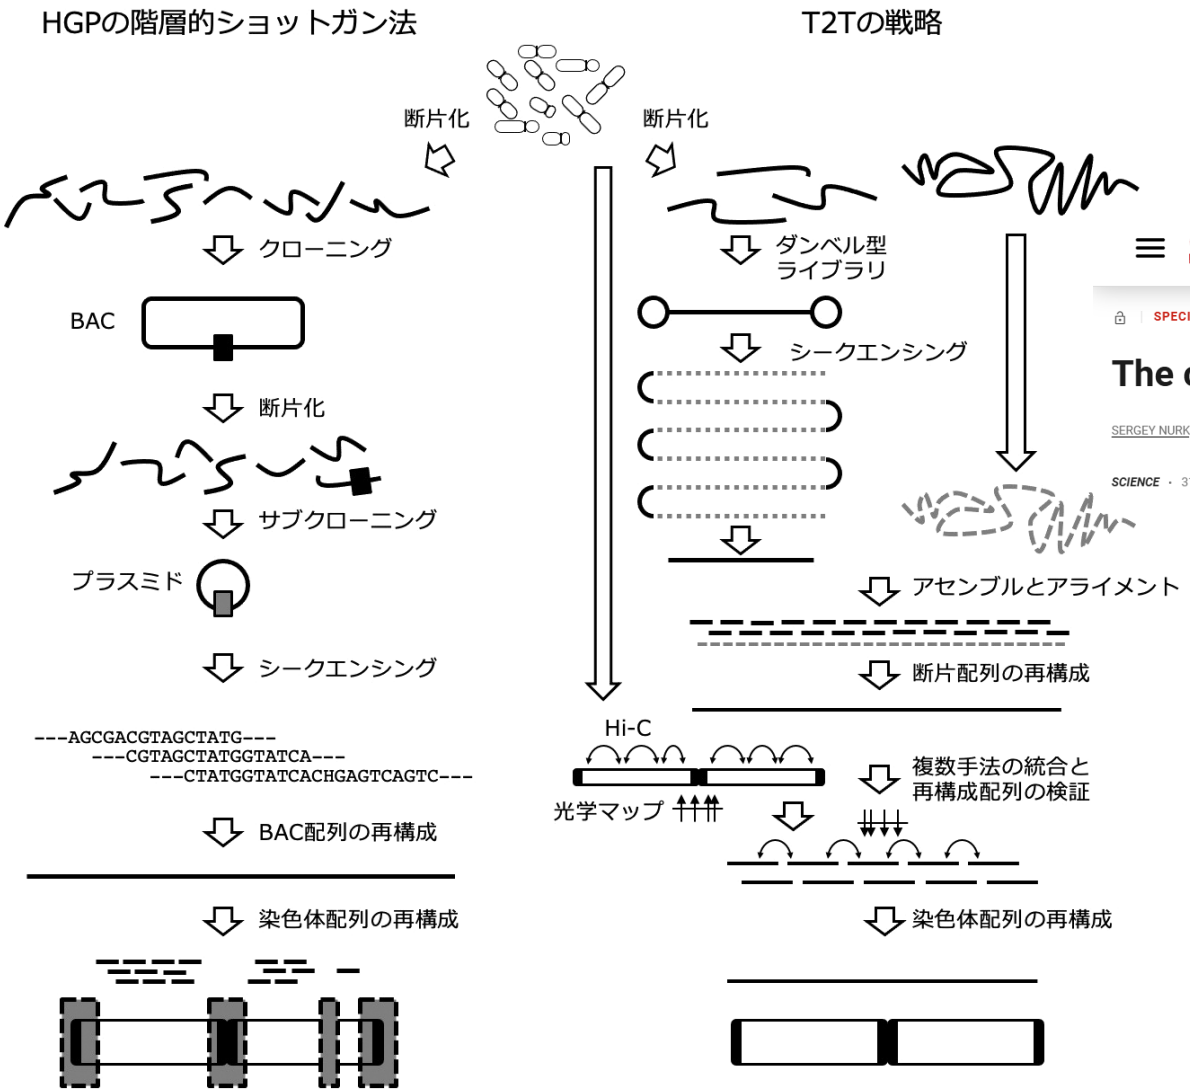
より正確なゲノム構造を解明することが可能に

The Telomere-to-Telomere (T2T) consortium

2003年度に完成させたヒトゲノムには読み切れていない場所が341箇所あった。



The Telomere-to-Telomere (T2T) consortium




Science Current Issue First release papers More

SPECIAL ISSUE RESEARCH ARTICLE | HUMAN GENOMICS

The complete sequence of a human genome

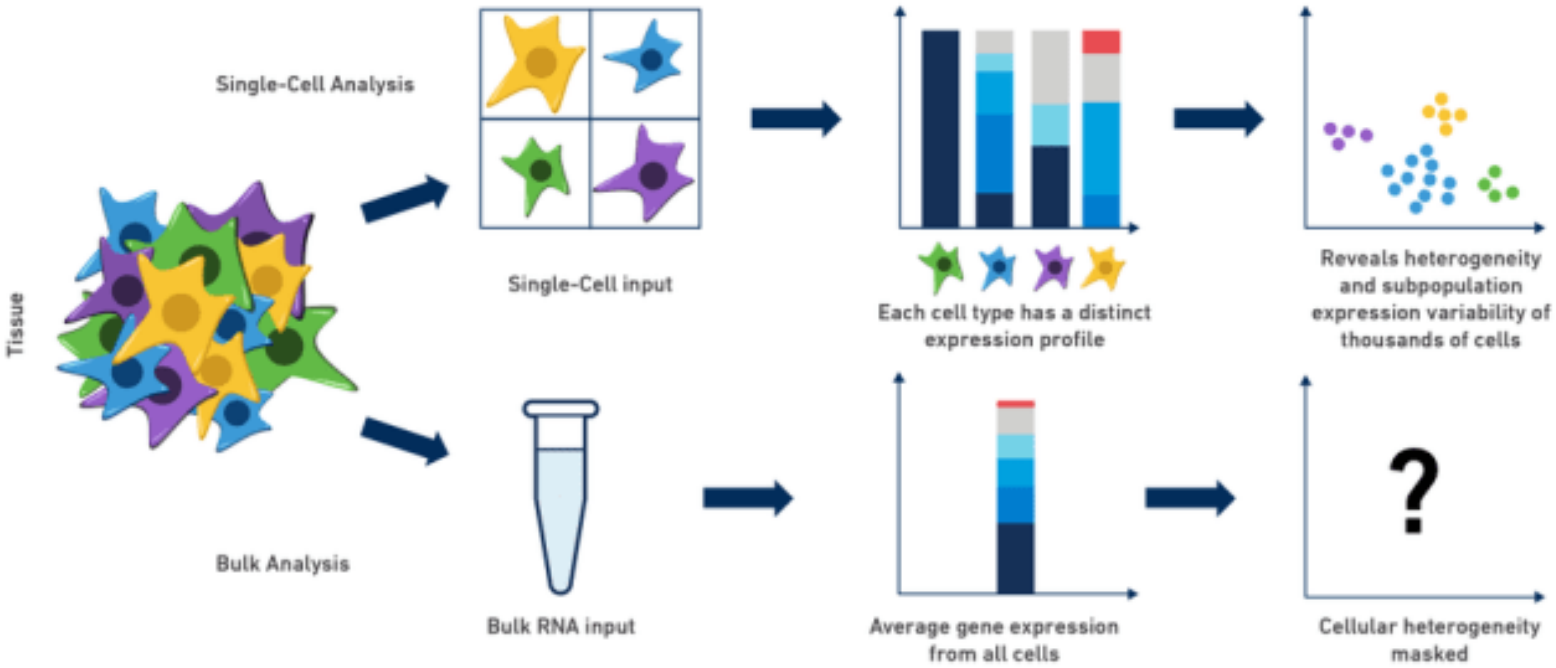
SERGEY NURK, SERGEY KOREN, [...], AND ADAM M. PHILLIPPY +97 authors Authors Info & Affiliations

SCIENCE · 31 Mar 2022 · Vol 376, Issue 6588 · pp. 44-53 · DOI: 10.1126/science.abj6987

更なる技術の進歩: Single-cell / Spatial sequencing

- Single cell RNA-seq

  組織全体での遺伝子発現量　→　1細胞ごとの遺伝子発現量

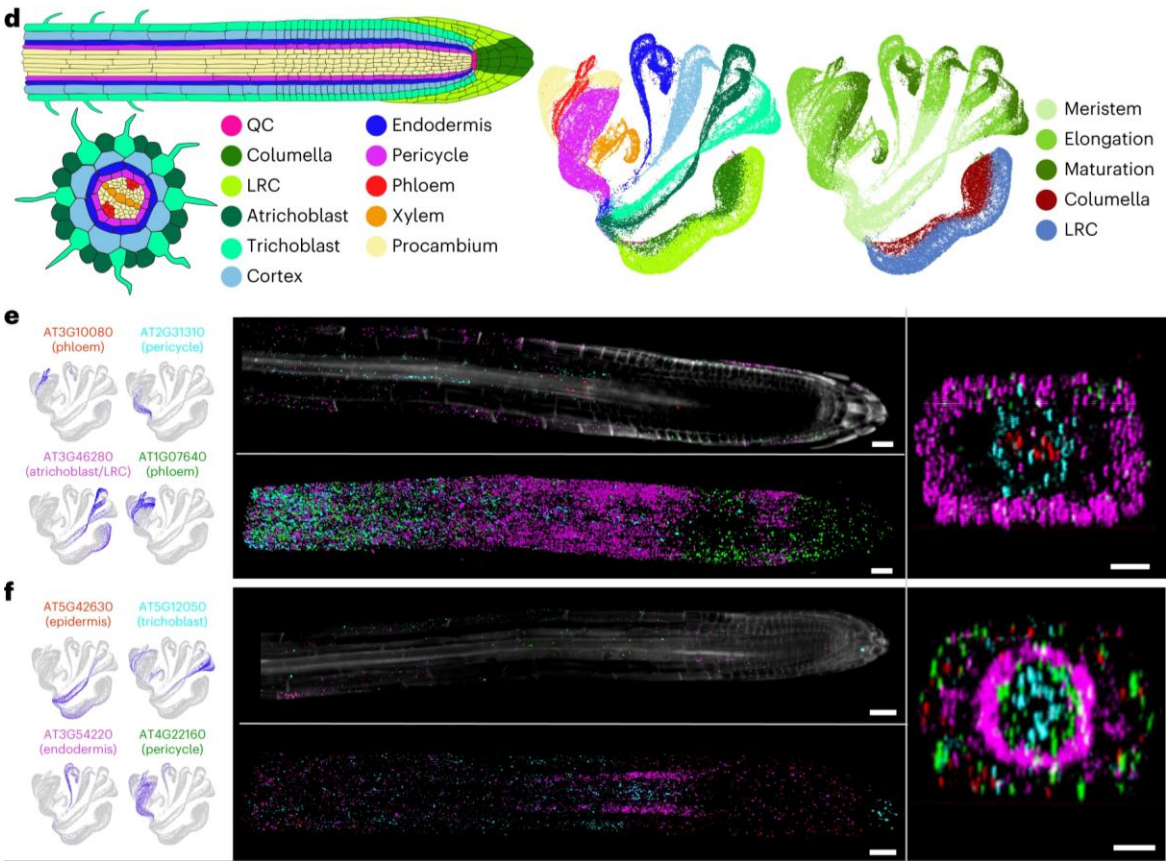


更なる技術の進歩: Single-cell / Spatial sequencing

- Spatial sequencing

  遺伝子の発現量を細胞ごとにマップすることが可能に

  ex) PHYTOMap

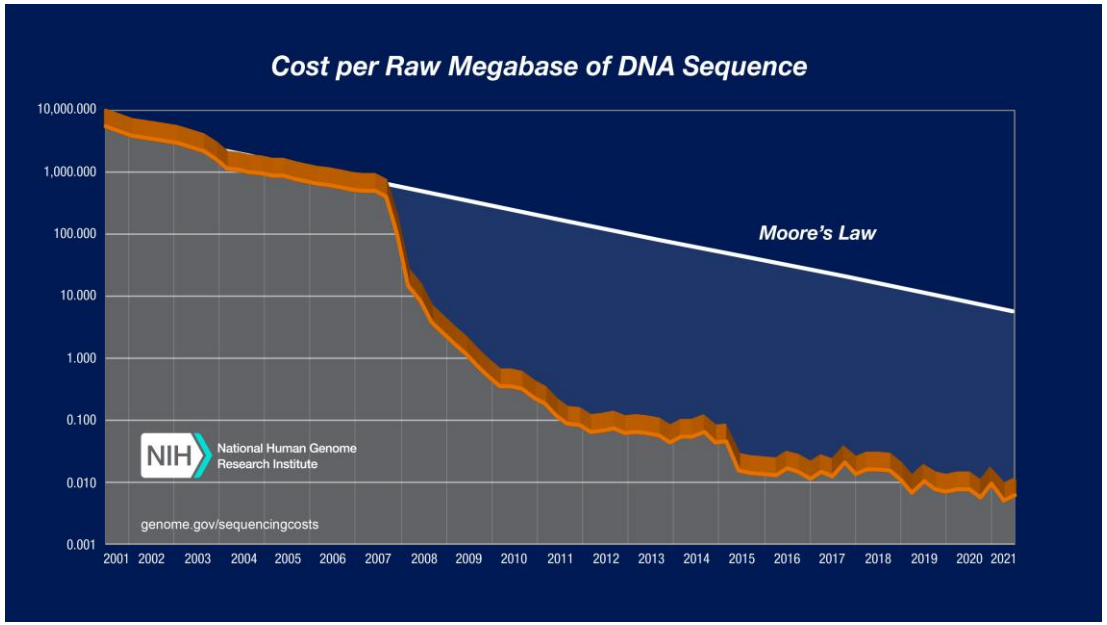


Nobori et al., 2023

その他: 技術の進歩によるシーケンスのコスト低下

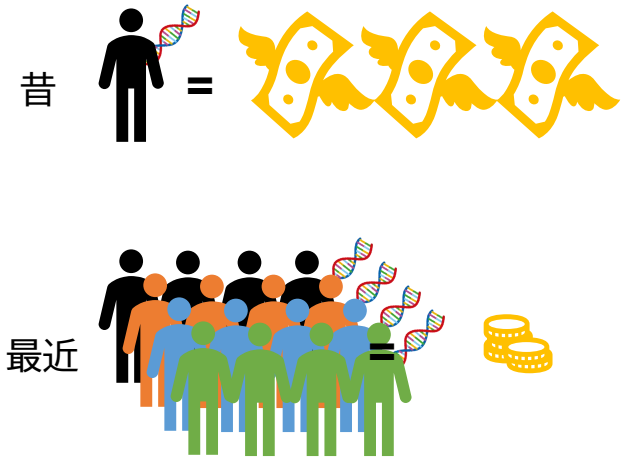
次世代シーケンサー登場前(15年前)からだと約数百万分の1
登場後(10年前)からでも約数十分の1に低下、今もなお低下し続けている

ex)ヒトゲノム(3Gb)…$20,000,000 → $1,000以下の時代に



シーケンスコスト

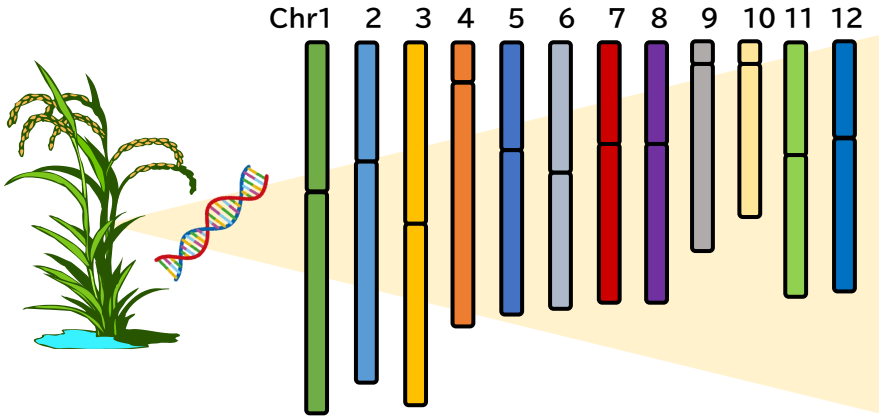
年



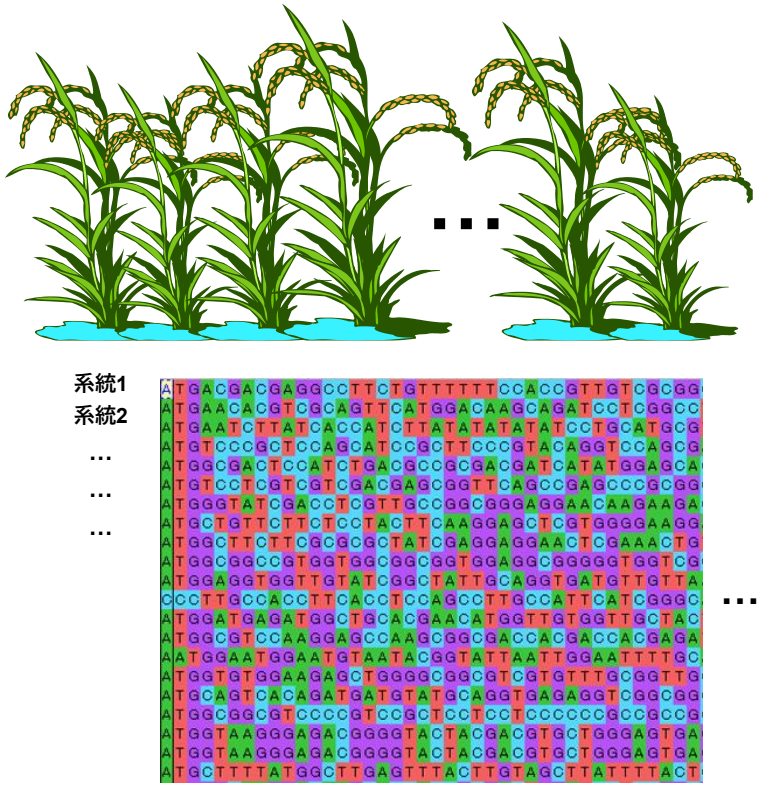
集団のゲノム情報が個人レベルで活用可能に

https://www.ncbi.nlm.nih.gov/datasets/genome/?taxon=4530

2004年 全ゲノム配列が読まれる(国際共同研究)



今：交配集団などの全個体のゲノム情報



nature

Explore content ⌄ About the journal ⌄ Publish with us ⌄

nature › articles › article

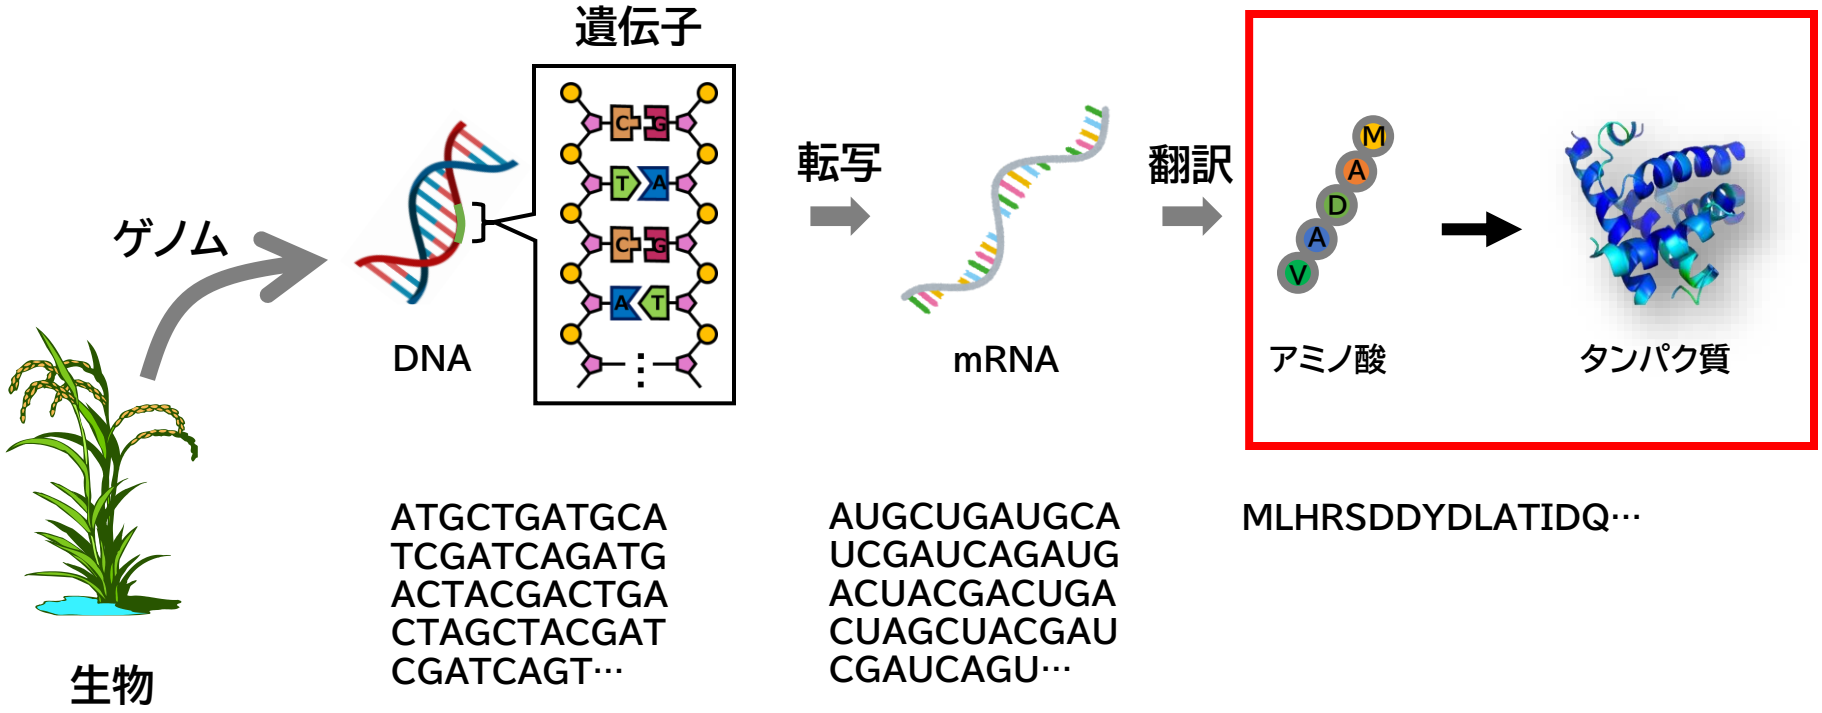
Published: 11 August 2005

The map-based sequence of the rice genome

International Rice Genome Sequencing Project & Takuji Sasaki

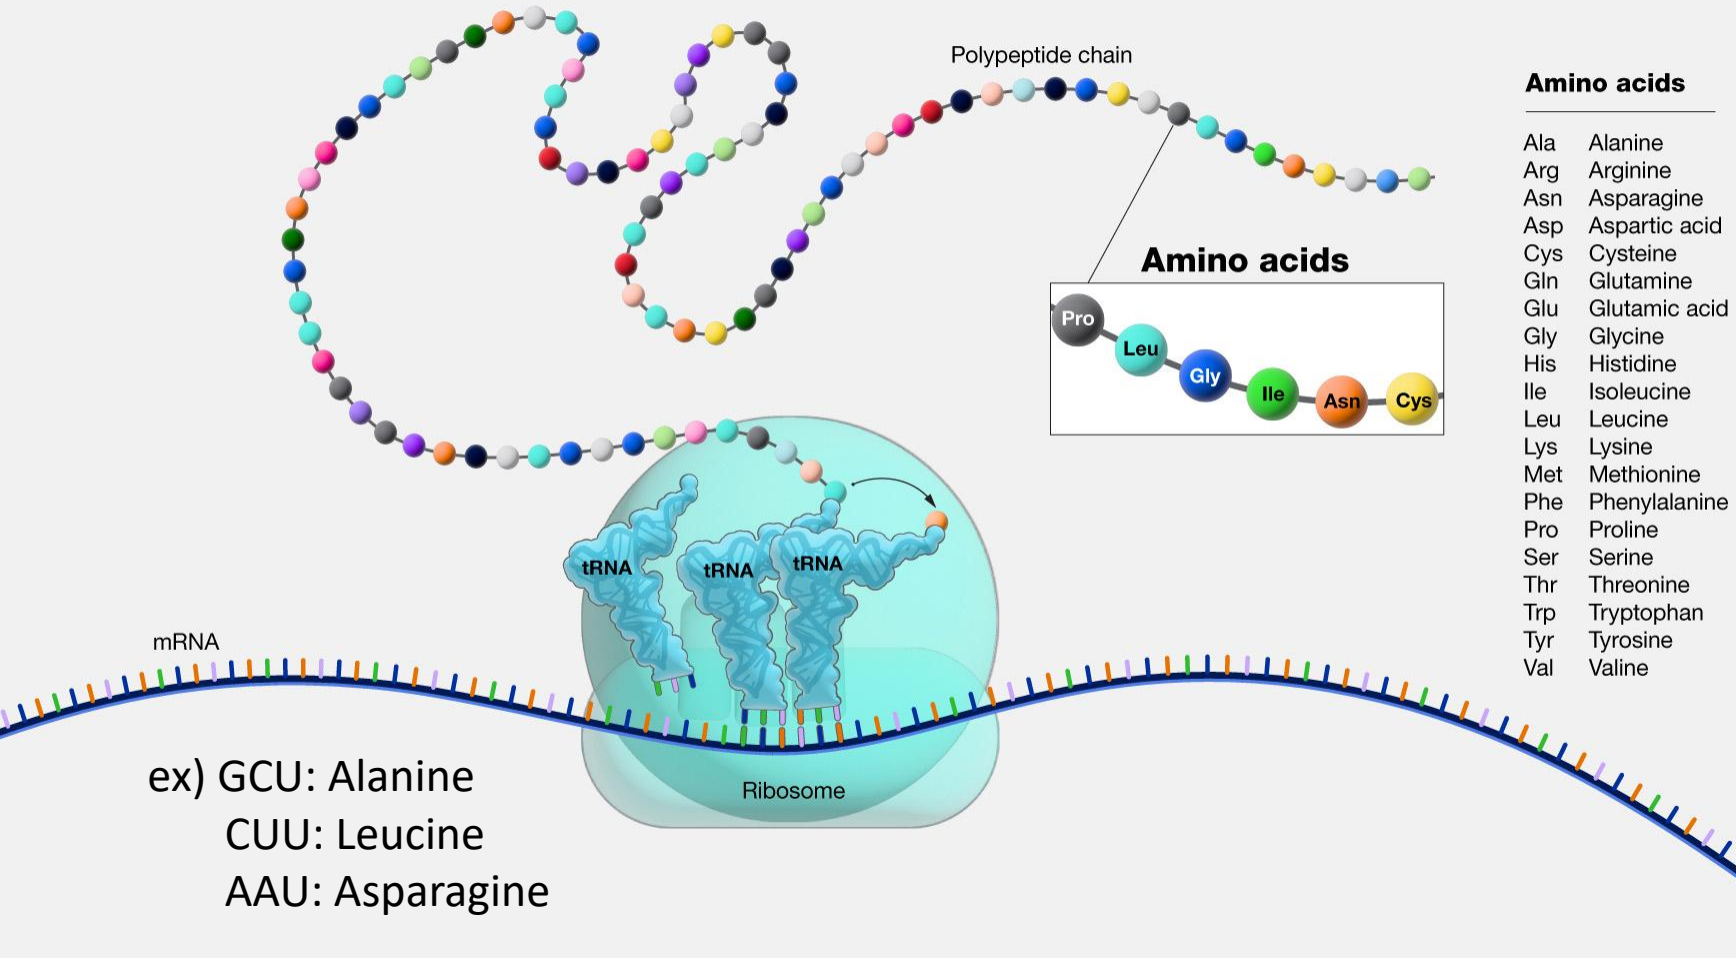
配列の先へ: アミノ酸配列の構造解析

分子生物学の基本原則: セントラルドグマ



遺伝子は転写・翻訳を経てタンパク質が合成され機能する

アミノ酸配列への翻訳



Amino acids

Ala	Alanine
Arg	Arginine
Asn	Asparagine
Asp	Aspartic acid
Cys	Cysteine
Gln	Glutamine
Glu	Glutamic acid
Gly	Glycine
His	Histidine
Ile	Isoleucine
Leu	Leucine
Lys	Lysine
Met	Methionine
Phe	Phenylalanine
Pro	Proline
Ser	Serine
Thr	Threonine
Trp	Tryptophan
Tyr	Tyrosine
Val	Valine

ex) GCU: Alanine
CUU: Leucine
AAU: Asparagine

https://www.genome.gov/genetics-glossary/Amino-Acids

遺伝子は転写・翻訳を経てタンパク質が合成され機能する

アミノ酸配列は立体構造を形成し、タンパク質として機能する

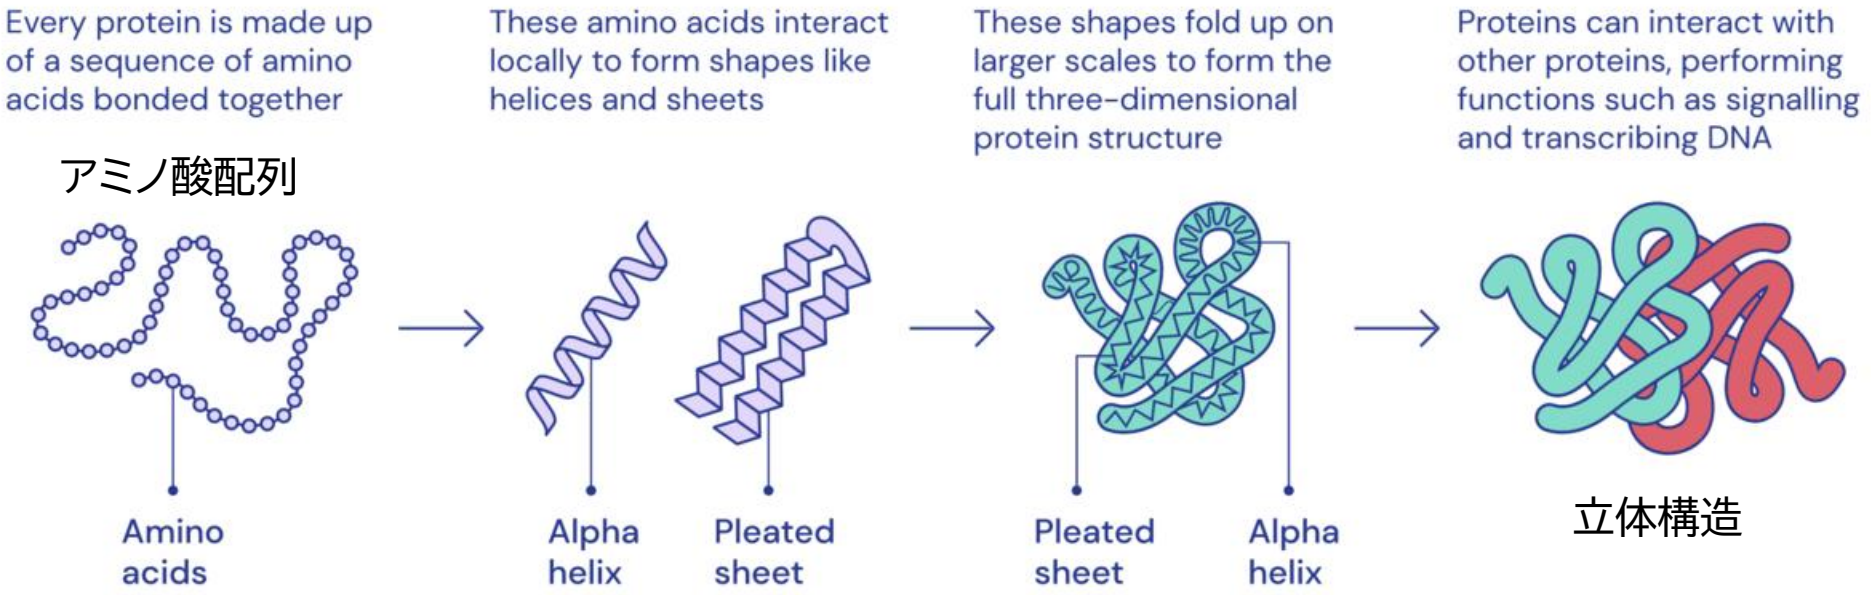


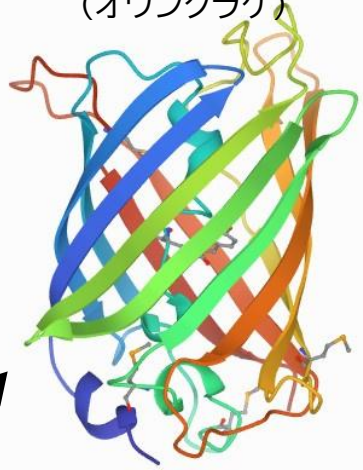
Figure 1: Complex 3D shapes emerge from a string of amino acids.

https://deepmind.com/blog/article/AlphaFold-Using-AI-for-scientific-discovery
https://www.genome.gov/genetics-glossary/Amino-Acids

遺伝子は転写・翻訳を経てタンパク質が合成され機能する

有名なタンパク質の構造例　https://www.rcsb.org/

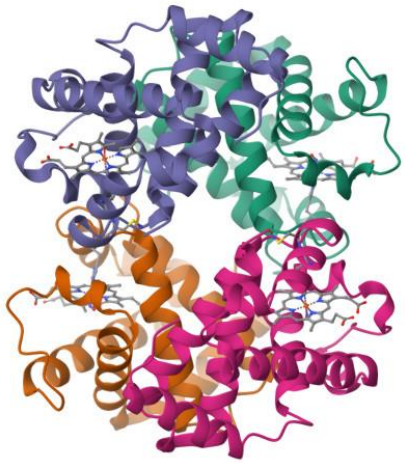
緑色蛍光タンパク
Green Fluorescent Protein (GFP)
（オワンクラゲ）



PDB 1EMA

MSKGEELFTGVVPILVELDGDVNGHKFSV
SGEGEGDATYGKLTLKFICTTGKLPVPWPT
LVTTFXVQCFSRYPDHMKRHDFFKSAMP
EGYVQERTIFFKDDGNYKTRAEVKFEGDT
LVNRIELKGIDFKEDGNILGHKLEYNYNSH
NVYIMADKQKNGIKVNFKIRHNIEDGSVQ
LADHYQQNTPIGDGPVLLPDNHYLSTQS
ALSKDPNEKRDHMVLLEFVTAAGITHGM
DELYK

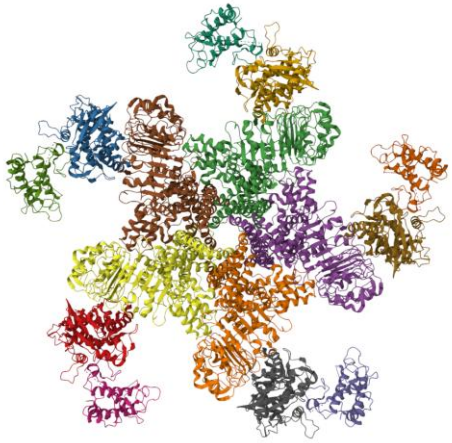
ヘモグロビン
(ヒト)



PDB 1BUW

VLSPADKTNVKAAWGKVGAHAGEYGAEALER
MFLSFPTTKTYFPHFDLSHGSAQVKGHGKKVA
DALTNAVAHVDDMPNALSALSDLHAHKLRVD
PVNFKLLSHCLLVTLAAHLPAEFTPAVHASLDKF
LASVSTVLTSKYRVHLTPEEKSAVTALWGKVNV
DEVGGEALGRLLVVYPWTQRFFESFGDLSTPDA
VMGNPKVKAHGKKVLGAFSDGLAHLDNLKGT
FATLSELHCDKLHVDPENFRLLGNVLVCVLAHH
FGKEFTPPVQAAYQKVVAGVANALAHKYH

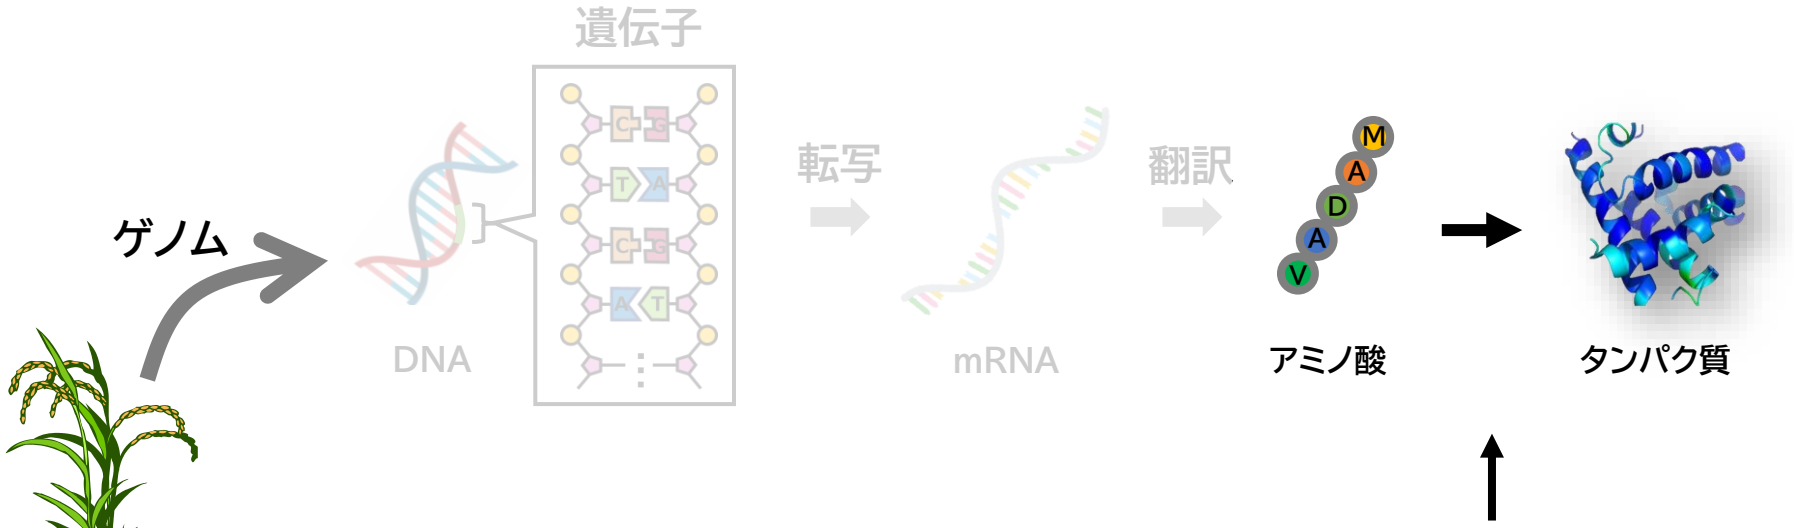
ZAR1
(シロイヌナズナ)



PDB 6J5T

MVDAVVTVFLEKTLNILEEKGRTVSDYRKQLEDLQSELKYMQSFLKDAERQKRTNETLRTLVA
DLRELVYEAEDILVDCQLADGDDGNEQRSSNAWLSRLHPARVPLQYKKSKRLQEINERITKIK
SQVEPYFEFITPSNVGRDNGTDRWSSPVYDHTQVVGLEGDKRKIKEWLFRSNDSQLLIMAF
VGMGGLGKTTIAQEVFNDKEIEHRFERRIWVSVSQTFTEEQIMRSILRNLGDASVGDDIGTLL
RKIQQYLLGKRYLIVMDDVWDKNLSWWDKIYQGLPRGQGGSVIVTTRSESVAKRVQARDD
KTHRPELLSPDNSWLLFCNVAFAANDGTCERPELEDVGKEIVTKCKGLPLTIKAVGGLLLCKD
HVYHEWRRIAEHFQDELRGNTSETDNVMSSLQLSYDELPSHLKSCILTLSLYPEDCVIPKQQL
VHGWIGEGFVMWRNGRSATESGEDCFSGLTNRCLIEVVDKTYSGTIITCKIHDMVRDLVIDI
AKKDSFSNPEGLNCRHLGISGNFDEKQIKVNHKLRGVVSTTKTGEVNKLNSDLAKKFTDCKYL
RVLDISKSIFDAPLSEILDEIASLQHLACLSLSNTHPLIQFPRSMEDLHNLQILDASYCQNLKQL
QPCIVLFKKLLVLDMTNCGSLECFPKGIGSLVKLEVLLGFKPARSNNGCKLSEVKNLTNLRKLG
LSLTRGDQIEEEELDSLINLSKLMSISINCYDSYGDDLITKIDALTPPHQLHELSLQFYPGKSSPS
WLSPHKLPMLRYMSICSGNLVKMQEPFWGNENTHWRIEGLMLSSLSDLDMDWEVLQQS
MPYLRTVTANWCPELESFAIEDVGFRGGVWMKTPLHRT

電子顕微鏡や画像解析技術により構造解析が可能に



クライオ電子顕微鏡

X線結晶構造解析法

核磁気共鳴(NMR)法

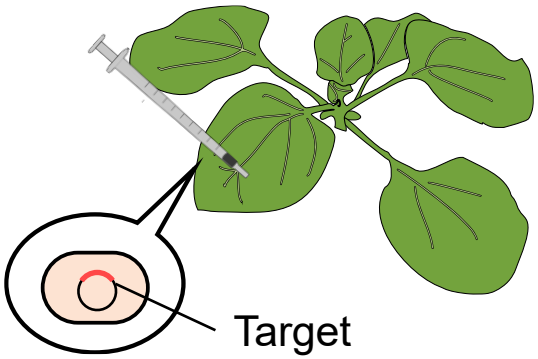
等。



例）クライオ電子顕微鏡によるタンパク質構造解析

Protein purification from *N. benthamiana* leaves

Agroinfiltration x 180 leaves

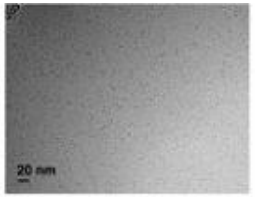


Target protein

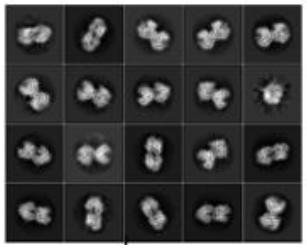


Cryo-EM structure analysis

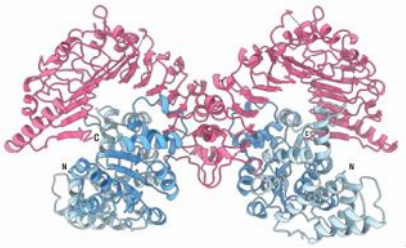
Take micrograph movies by Cyro-EM



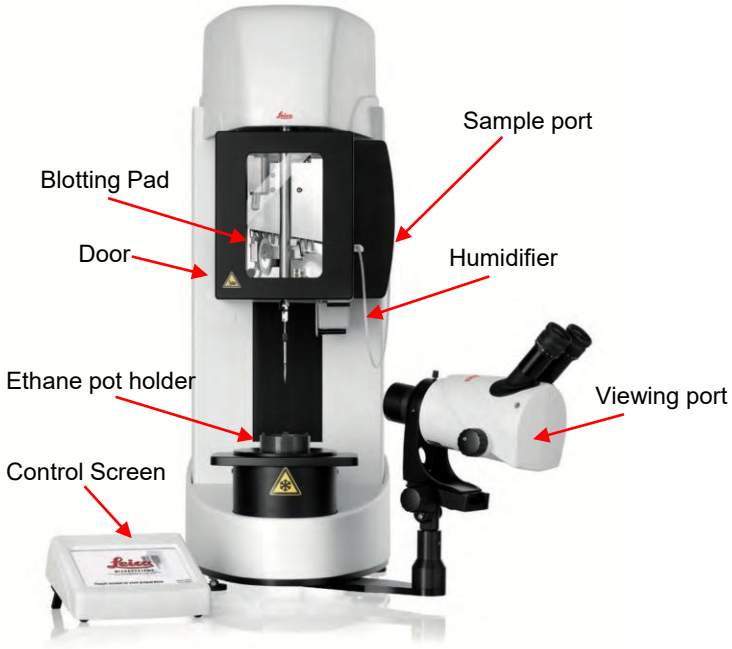
2D classification



Build 3D model



構造を視るにはOIST等の設備の整った場所が必要&時間もかかる

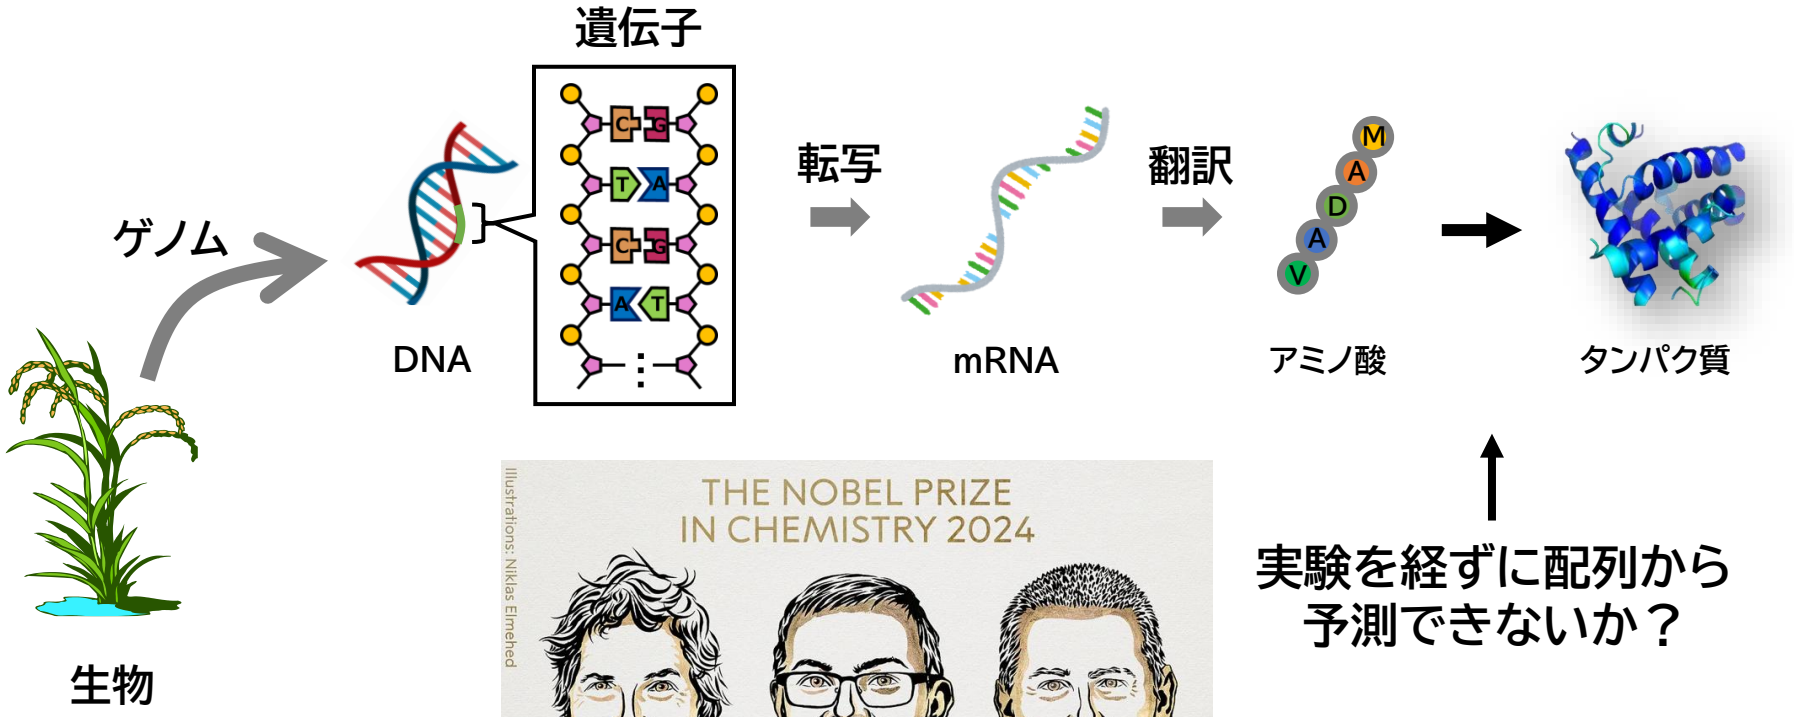


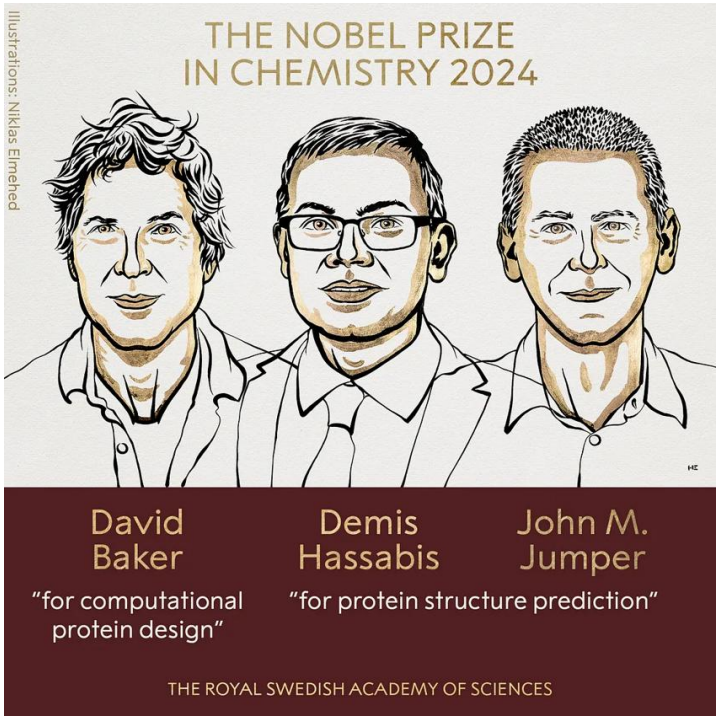


- そもそも綺麗なタンパク質の結晶を作成する難易度が非常に高い

  タンパク質の不安定さ、沈殿剤の種類、重力の影響など…
  膜タンパクなどはかなり難しい。

アミノ酸配列から構造を予測するモデルの開発





これまでのタンパク質構造データから予測モデルを構築

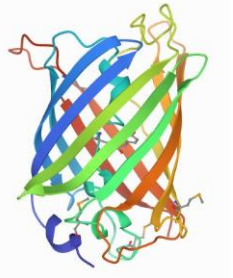
- PDB(Protein Data Bank)

  https://www.rcsb.org/

  … 過去50年間、構造生物学者達が行ってきた、
  約25万のタンパク質立体構造解析のデータ

- 蓄積されたデータを用いて予測モデルを作れないか？(教師あり学習)

MSKGEELFTGVVPILVEL
DGDVNG**H**KFSVLFTG**E**



アミノ酸配列が似ている

MSKGEELFTGVVPILVEL
DGDVNG**P**KFSVLFTG**V**

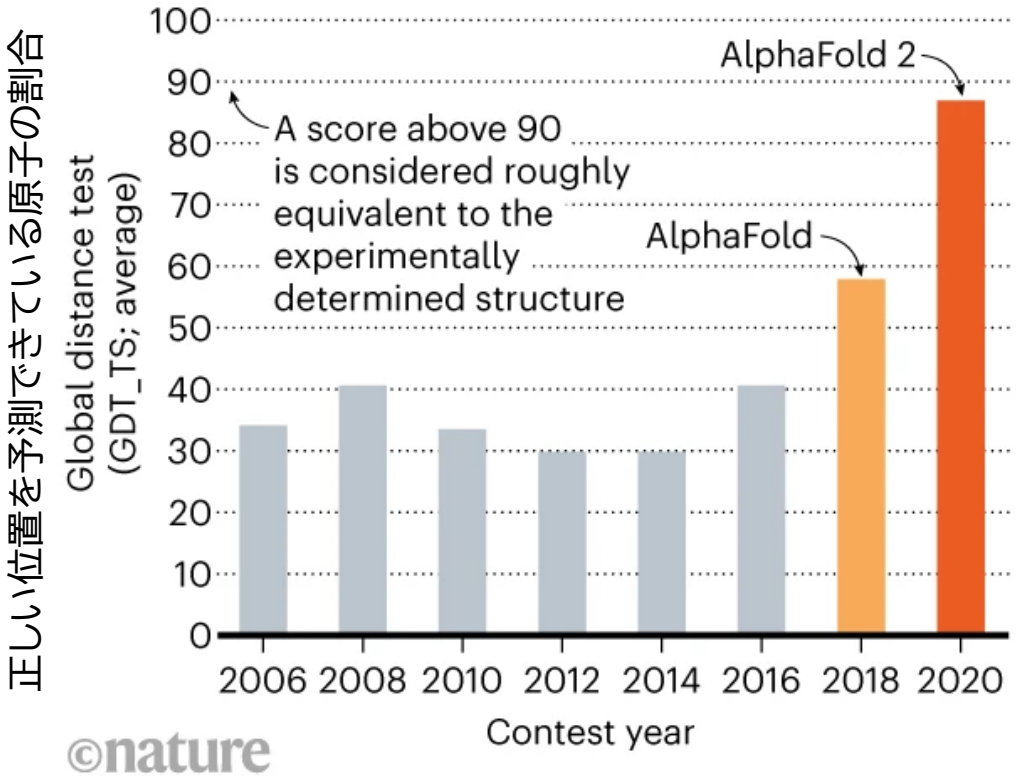


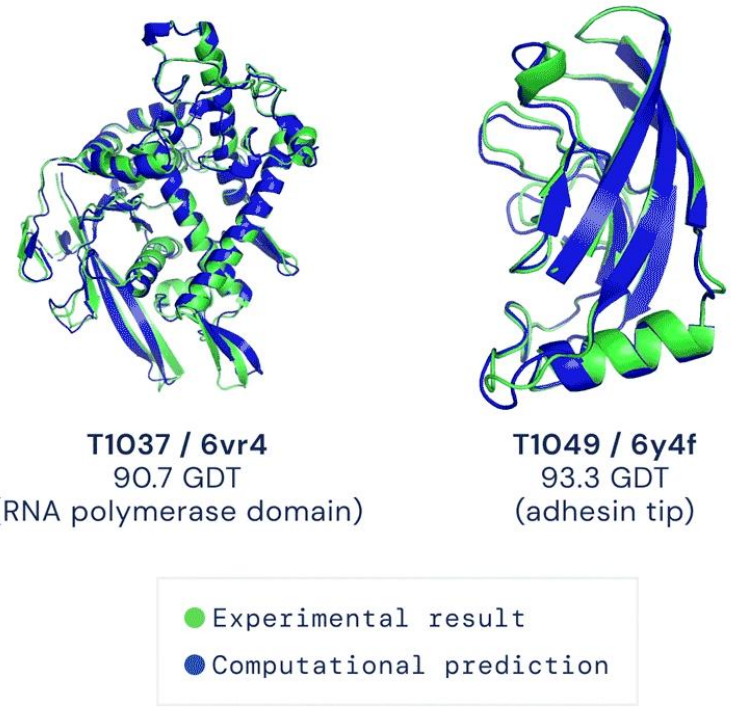
似た立体構造の可能性が高い

アミノ酸配列から計算だけで実験レベルの予測が可能に

- 2020年まで … 予測結果は全く信用できない
- 2020年から … 十分参考になる



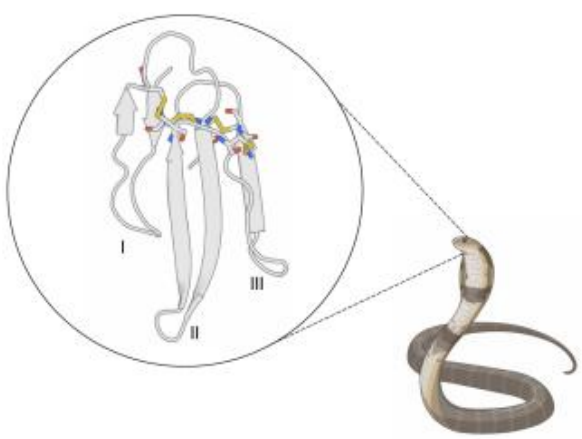


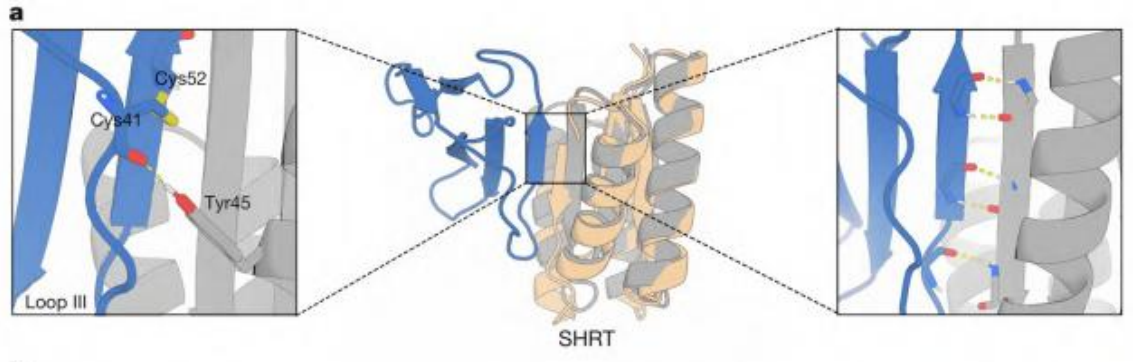


https://deepmind.google/blog/alphafold-a-solution-to-a-50-year-old-grand-challenge-in-biology/
https://www.nature.com/articles/d41586-020-03348-4

人工的に新しい遺伝子を設計することも可能な時代に

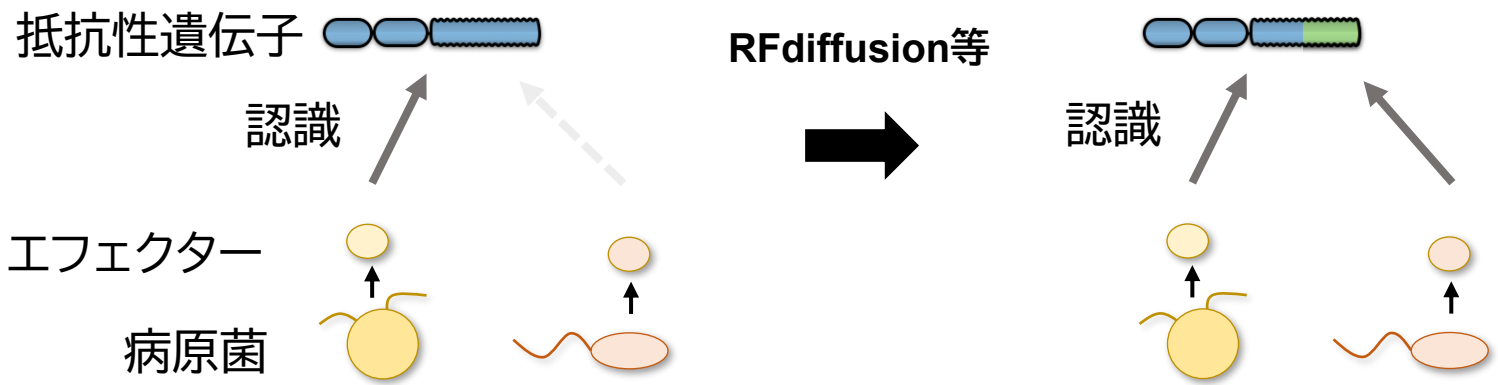
ex) ヘビ毒の毒素タンパク質に結合する人工タンパク質 (Baker et al., 2025)



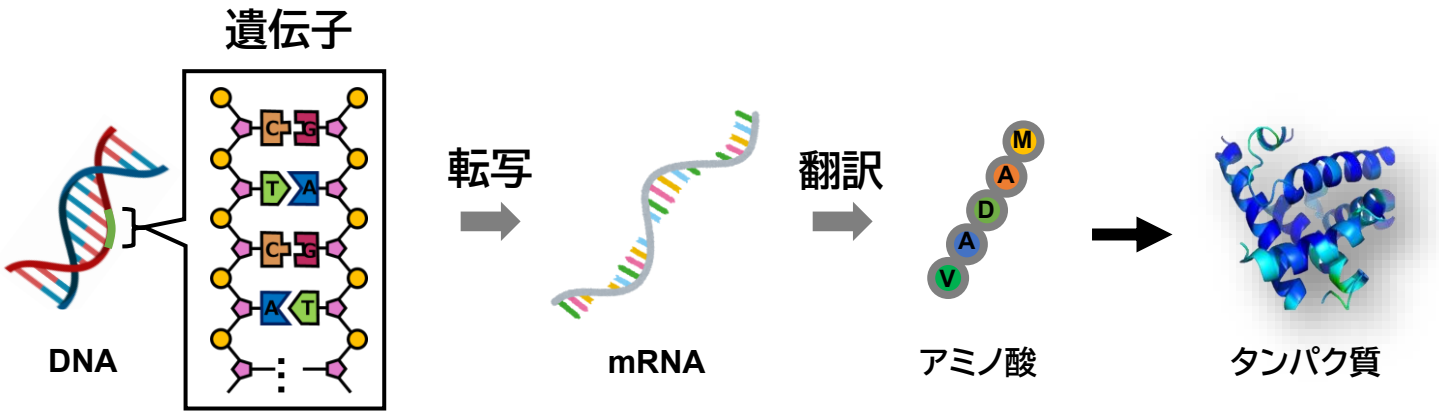


→マウスに毒素投与後生存確認

ex) 治療薬への応用や、抵抗性遺伝子のエンジニアリングも可能に



一旦まとめ



- シーケンス技術の進歩でDNA、RNA、アミノ酸配列の解読が可能に
- 技術はさらに進歩し、より詳細な遺伝子の発現情報も取得可能に。
- 機械学習等を組み合わせ、タンパク質の構造予測も可能に。

↓

「ゲノム情報解析」

これらの情報を解析することで、生物学的な知見を得る

大規模なゲノム解析技術を用いた研究例:
大規模なイネ交配集団に基づく超越分離の解読やゲノム育種への活用



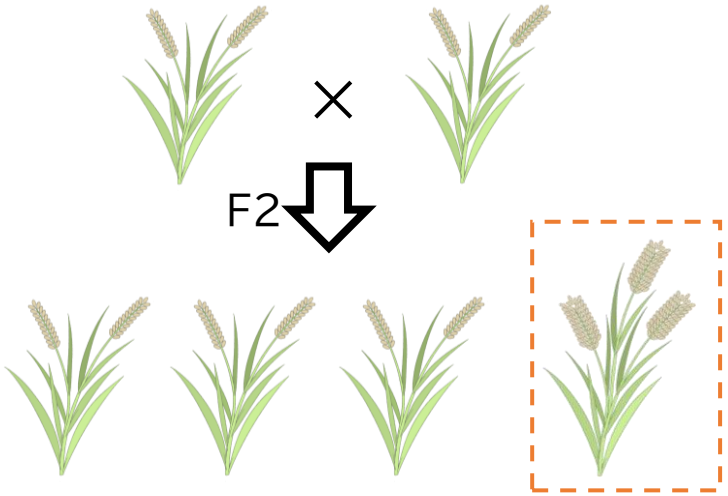
岩手県農業研究センター
Iwate Agricultural Research Center

公益財団法人
IBRC 岩手生物工学研究センター
Iwate Biotechnology Research Center

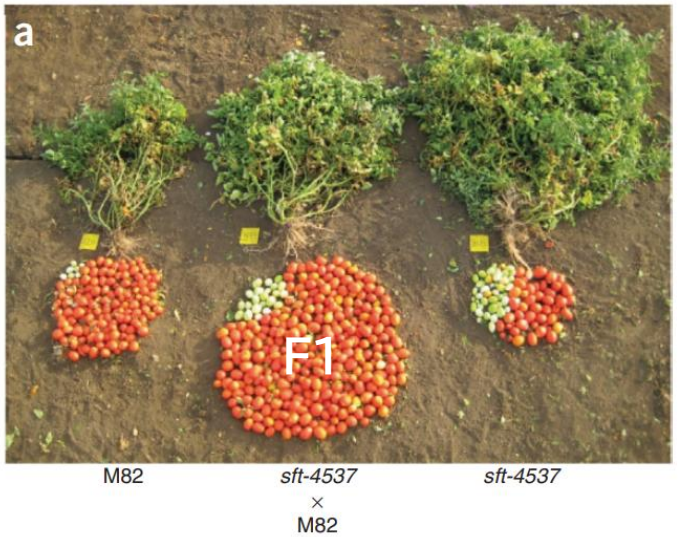
交雑をすると親を大幅に超える形質が見られることがある

- 意図的に生じさせる事が出来れば育種に有用

■超越分離



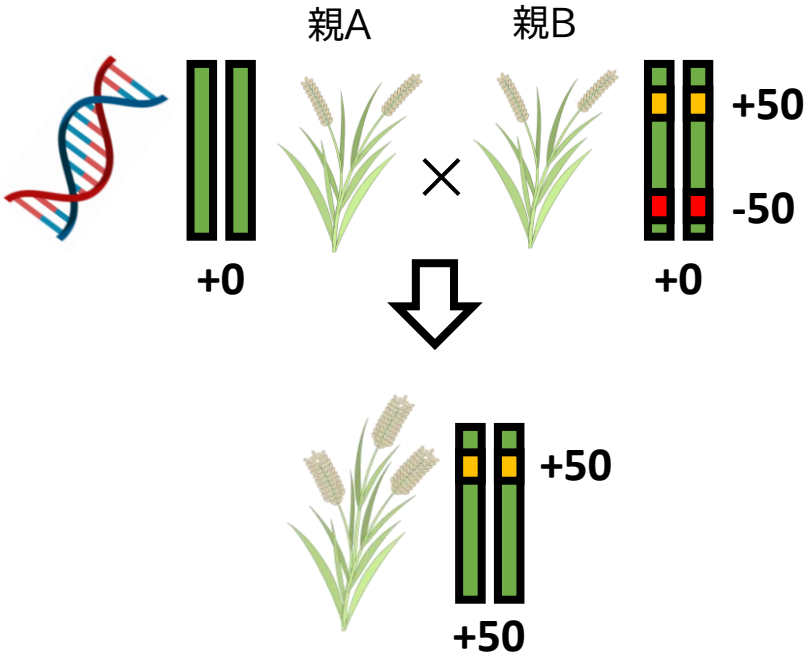
■ F1での雑種強勢



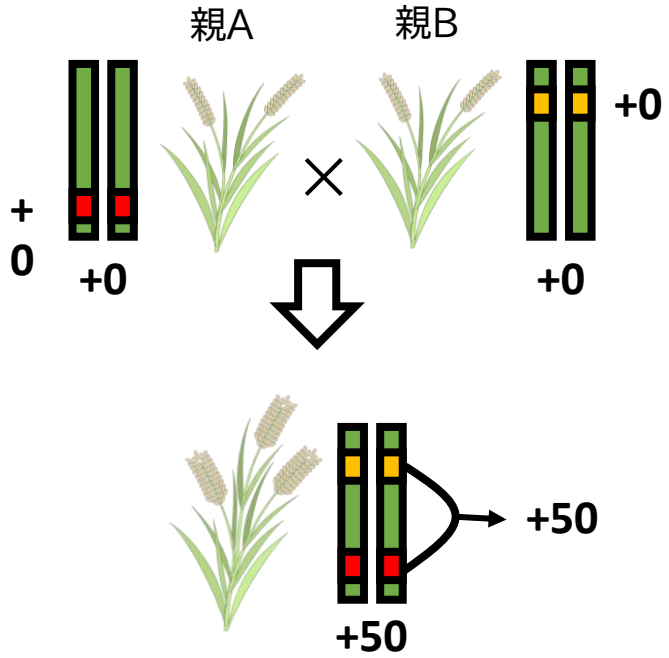
ex)SFT遺伝子
Krieger et al., 2010.

超越分離の原因として考えられる現象

■ 単純な例

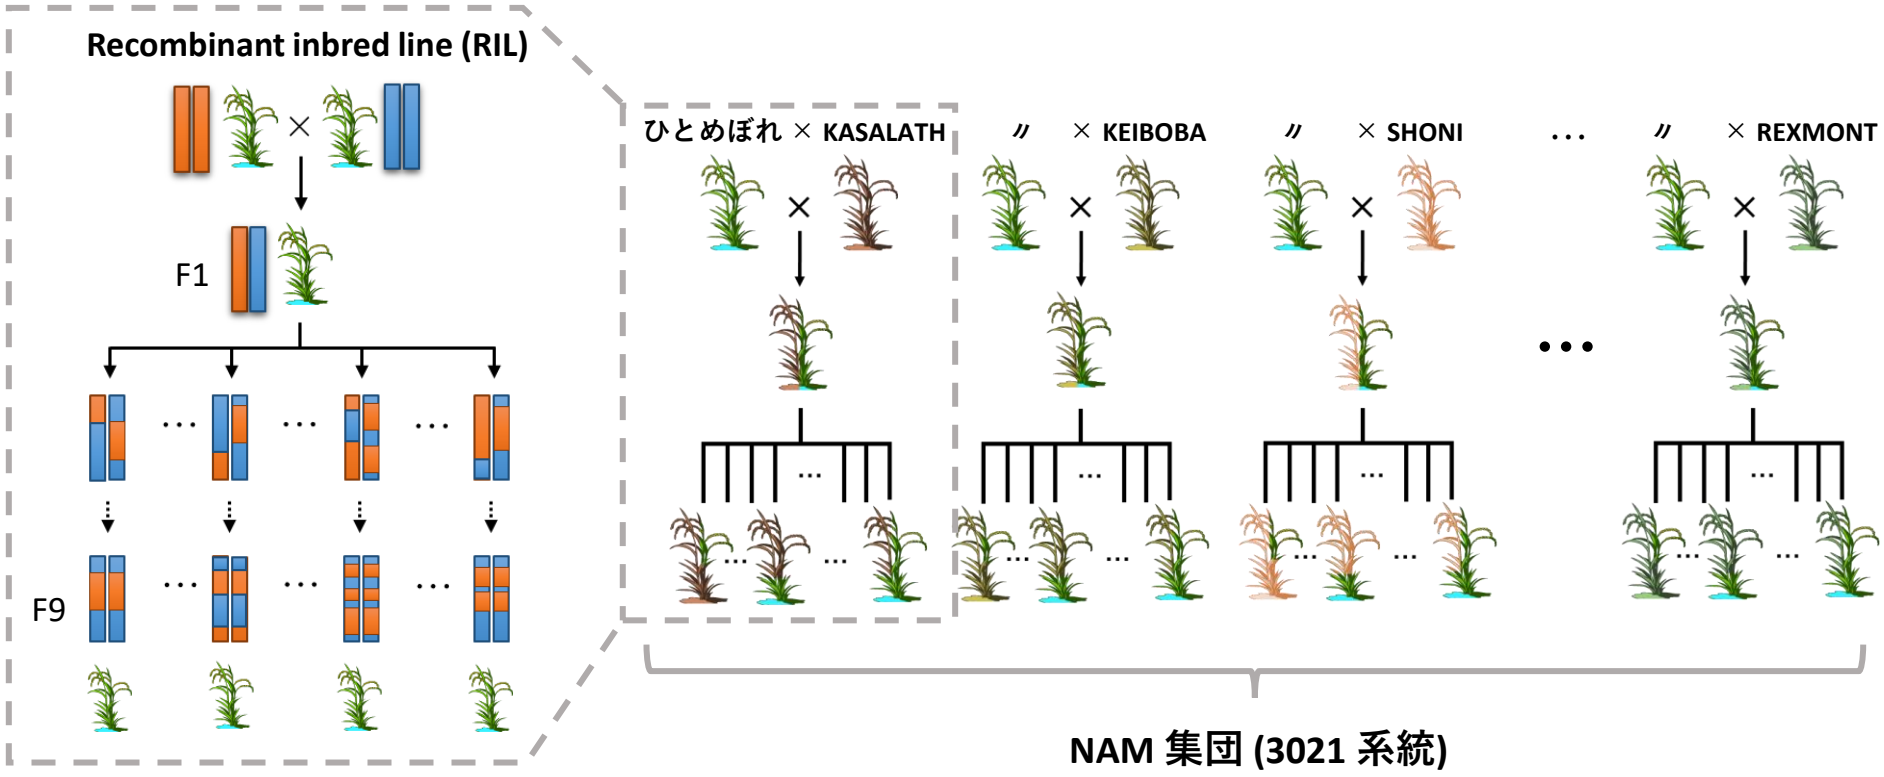


■ 特殊な例 (epistasis)

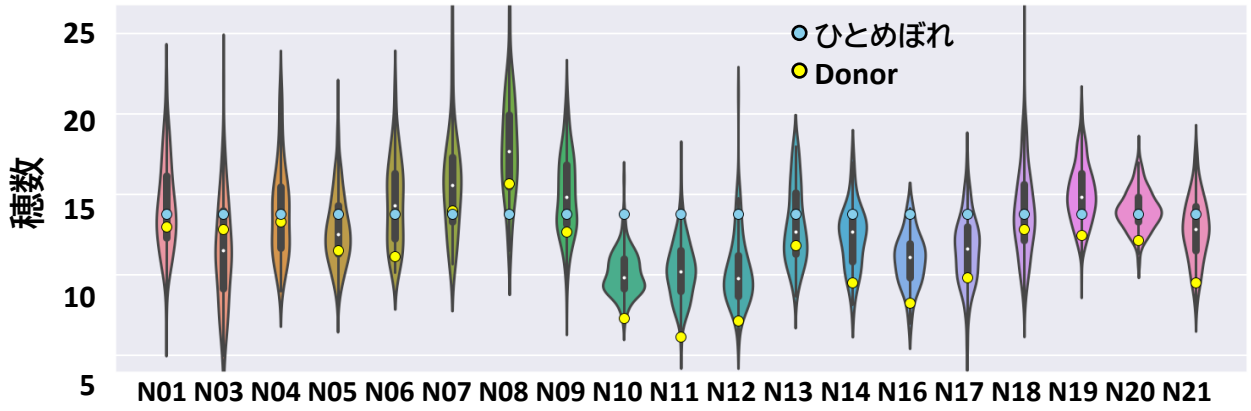


➢DNA配列が変化する影響力を細かく理解する必要がある

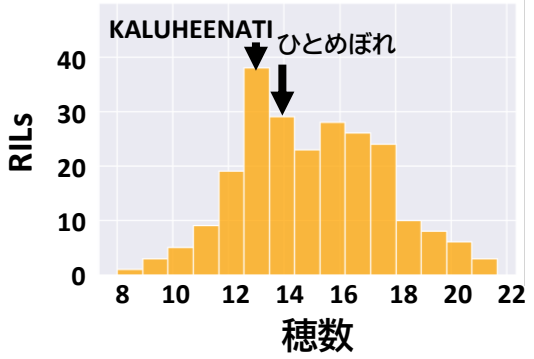
ひとめぼれ×20品種による交配集団を作成した



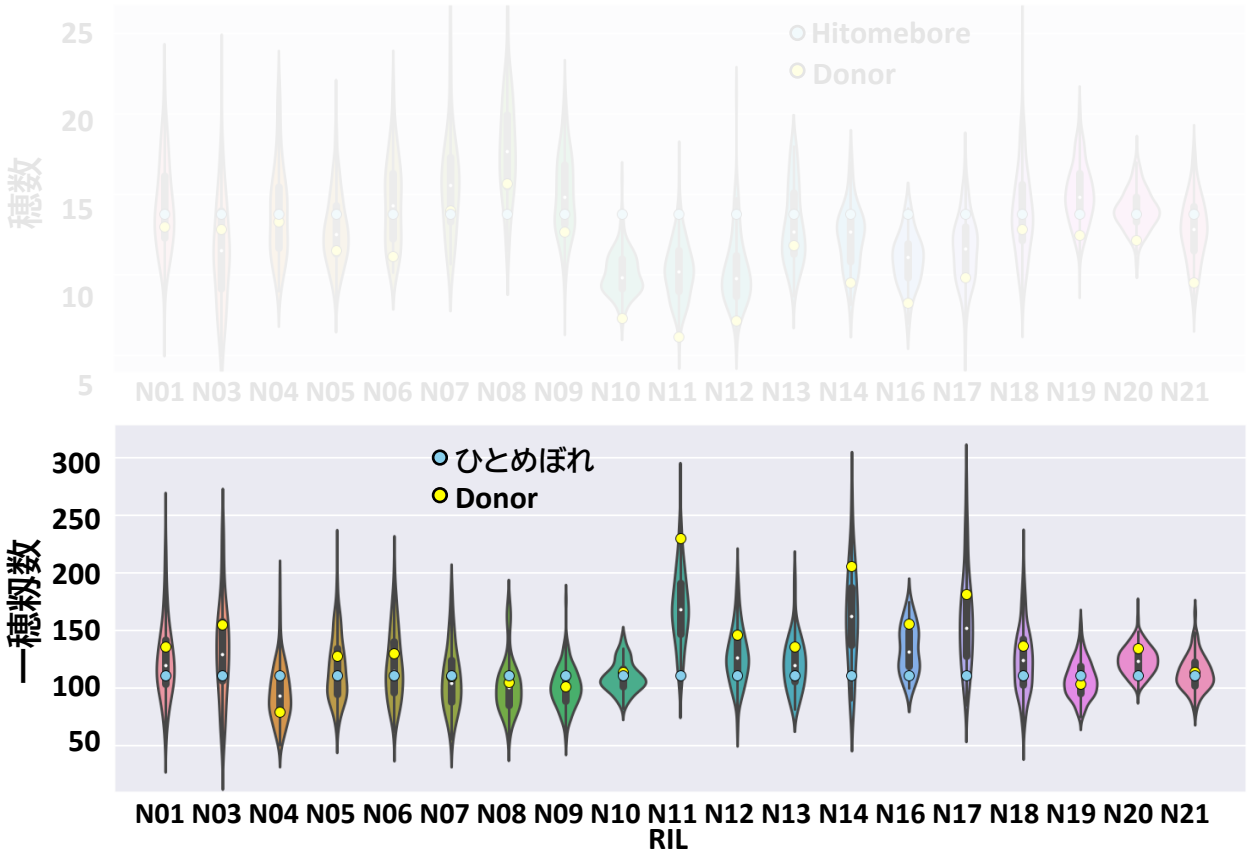
全ての形質、かなりの系統組み合わせで超越分離を確認



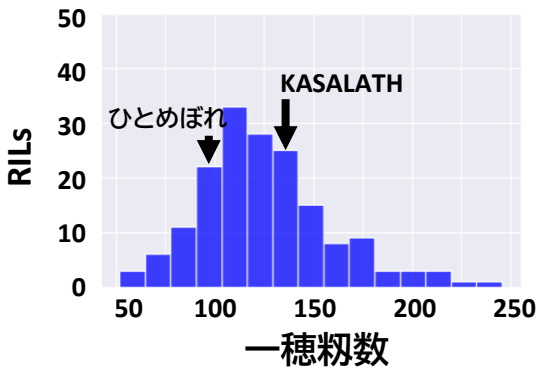
例) ひとめぼれ x KALUHEENATI



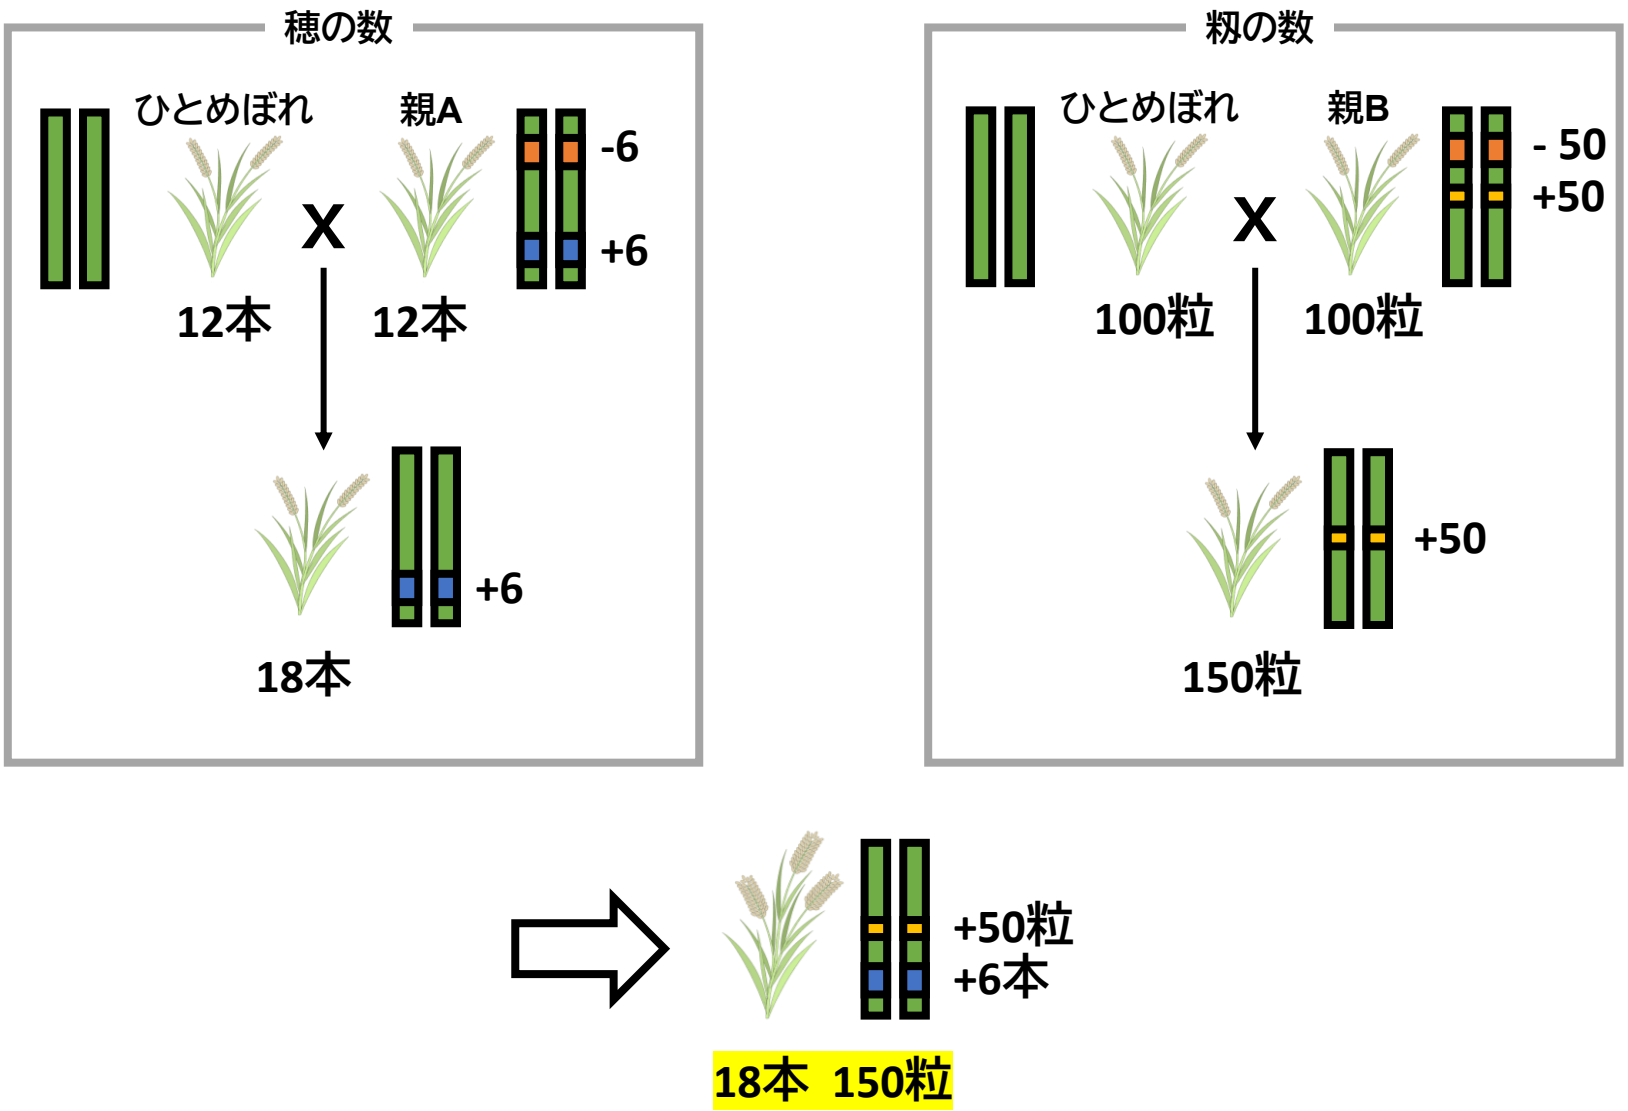
全ての形質、かなりの系統組み合わせで超越分離を確認



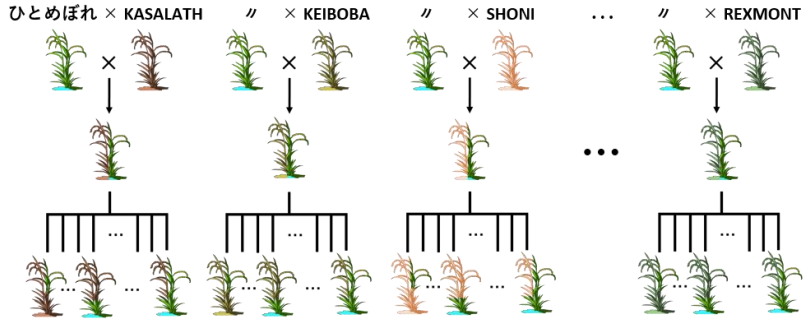
例) ひとめぼれ x KASALATH

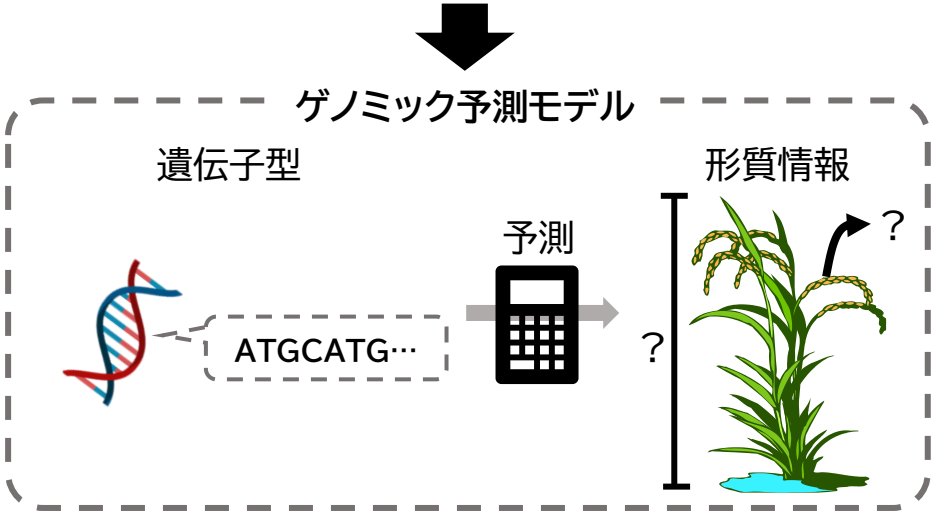


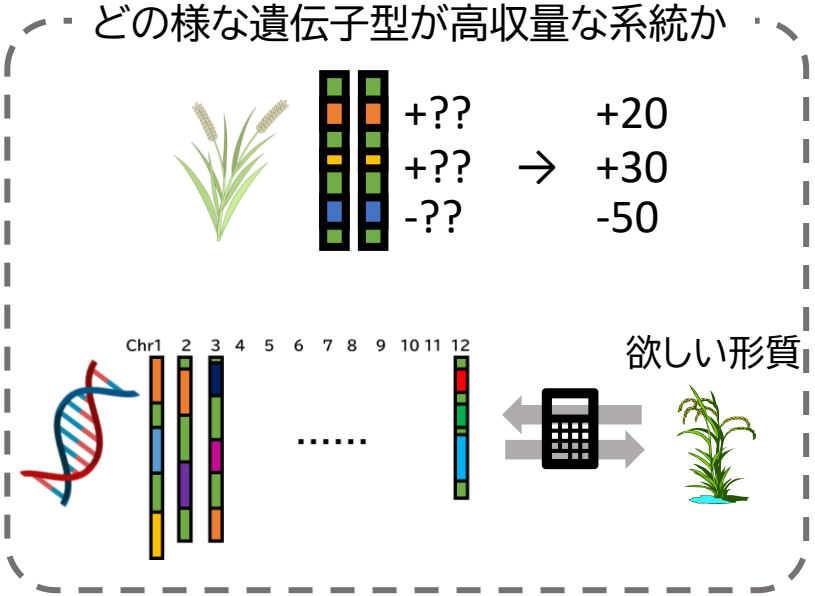
イネ交配集団では超越分離が多数見られた＝プラスの配列変化が多数



大規模集団を用いてDNA配列(遺伝子型)と形質値の関係性を捉える

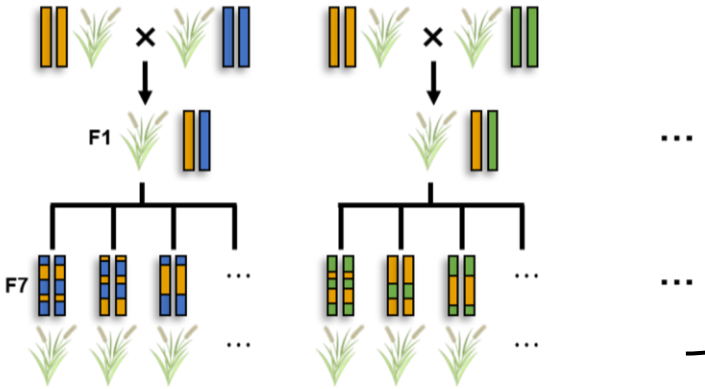




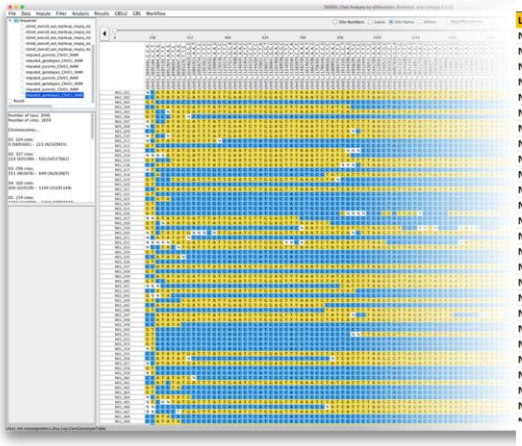


大規模交配集団を用いたゲノミックモデルの構築

交配集団 (3021系統)



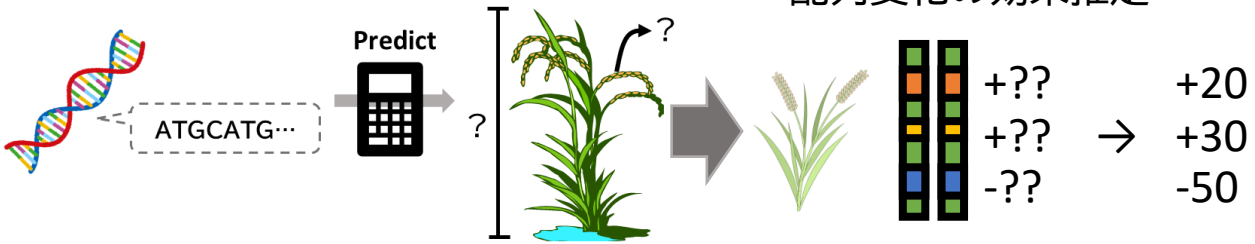
全系統のゲノム配列 →
遺伝子型　＆　形質情報
(48,888 Haplotype blocks)



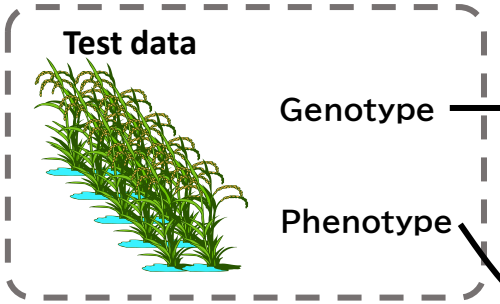
Line	LW_mean	GN_mean	GN_mean_ori	LL_mean	DTH_mean
N01_001	1.275	142.8833334	142.8833334	35.2	113.8
N01_002	1.1375	116.0666667	116.0666667	32.975	107.6
N01_003	1.3125	118.15	118.15	30.75	113
N01_004	1.1125	154.45	154.45	37.475	123.2
N01_005	1.5	128.8166667	128.8166667	29.725	115.8
N01_006	1.175	100.3166667	100.3166667	27.075	114.6
N01_007	1	79.21666666	79.21666666	25.75	106
N01_008	1.2125	159.1333334	159.1333334	33.675	105.8
N01_009	1.15	122.8833333	122.8833333	33.1	108.6
N01_010	1.5375	134.4	134.4	34.625	116
N01_011	0.875	82.16666667	82.16666667	34.15	108
N01_012	1.4125	153.7833334	153.7833334	37.175	108
N01_013	0.85	103.6666667	103.6666667	25	104.2
N01_014	1.1625	133.6	133.6	30.75	108.2
N01_015	1.2875	162.6	162.6	24.2	118.2
N01_016	1.175	130.7	130.7	36.4	121
N01_017	1.35	121.8333333	121.8333333	40.225	101.8
N01_018	1.0625	158.3	158.3	36.575	124.2
N01_019	1.2375	138.6166667	138.6166667	28.525	104
N01_020	1.3625	108.4	108.4	34.925	109.4
N01_021	1.275	133.6333334	133.6333334	33.4	115.2
N01_022	1.375	117.15	117.15	31.875	117.2
N01_023	1.3375	173.8	173.8	30.8	109.8
N01_024	1.4125	148.4666666	148.4666666	32.625	111.6
N01_025	1.25	118.9833333	118.9833333	31.425	108

予測モデルの構築

配列変化の効果推定



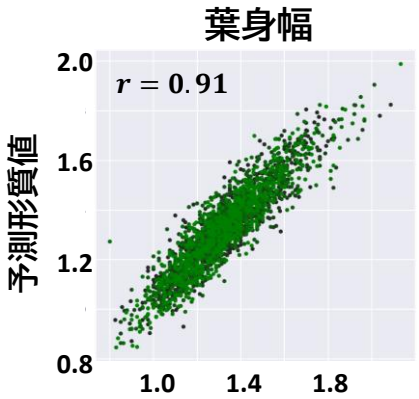
籾数・穂数・籾サイズ…etcに関して高精度のモデル構築に成功

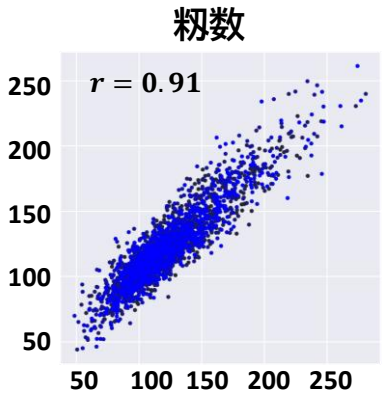


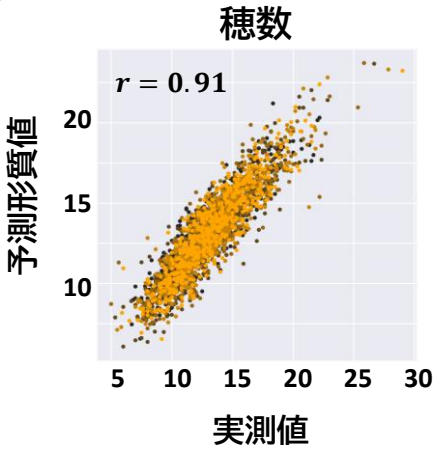
予測

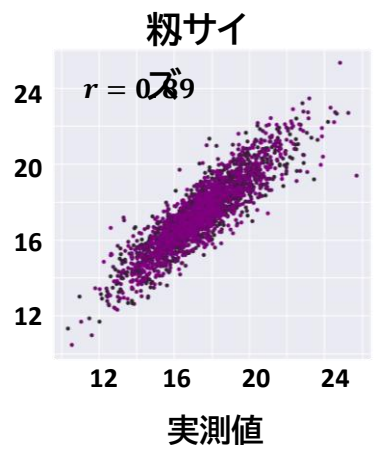
ElasticNet
+500 HBs

形質	相関係数(r)
籾サイズ	0.893
出穂期	0.902
籾数	0.913
葉身長	0.857
葉身幅	0.915
穂数	0.905
SPAD値	0.881
分げつ角度	0.814



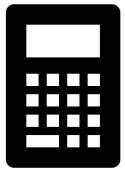






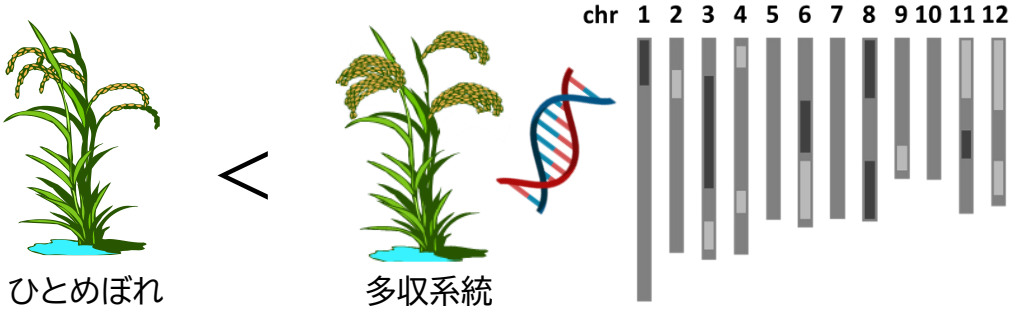
構築したモデルを用いて遺伝的効果を解明し、形質をカスタマイズする

高精度なモデル

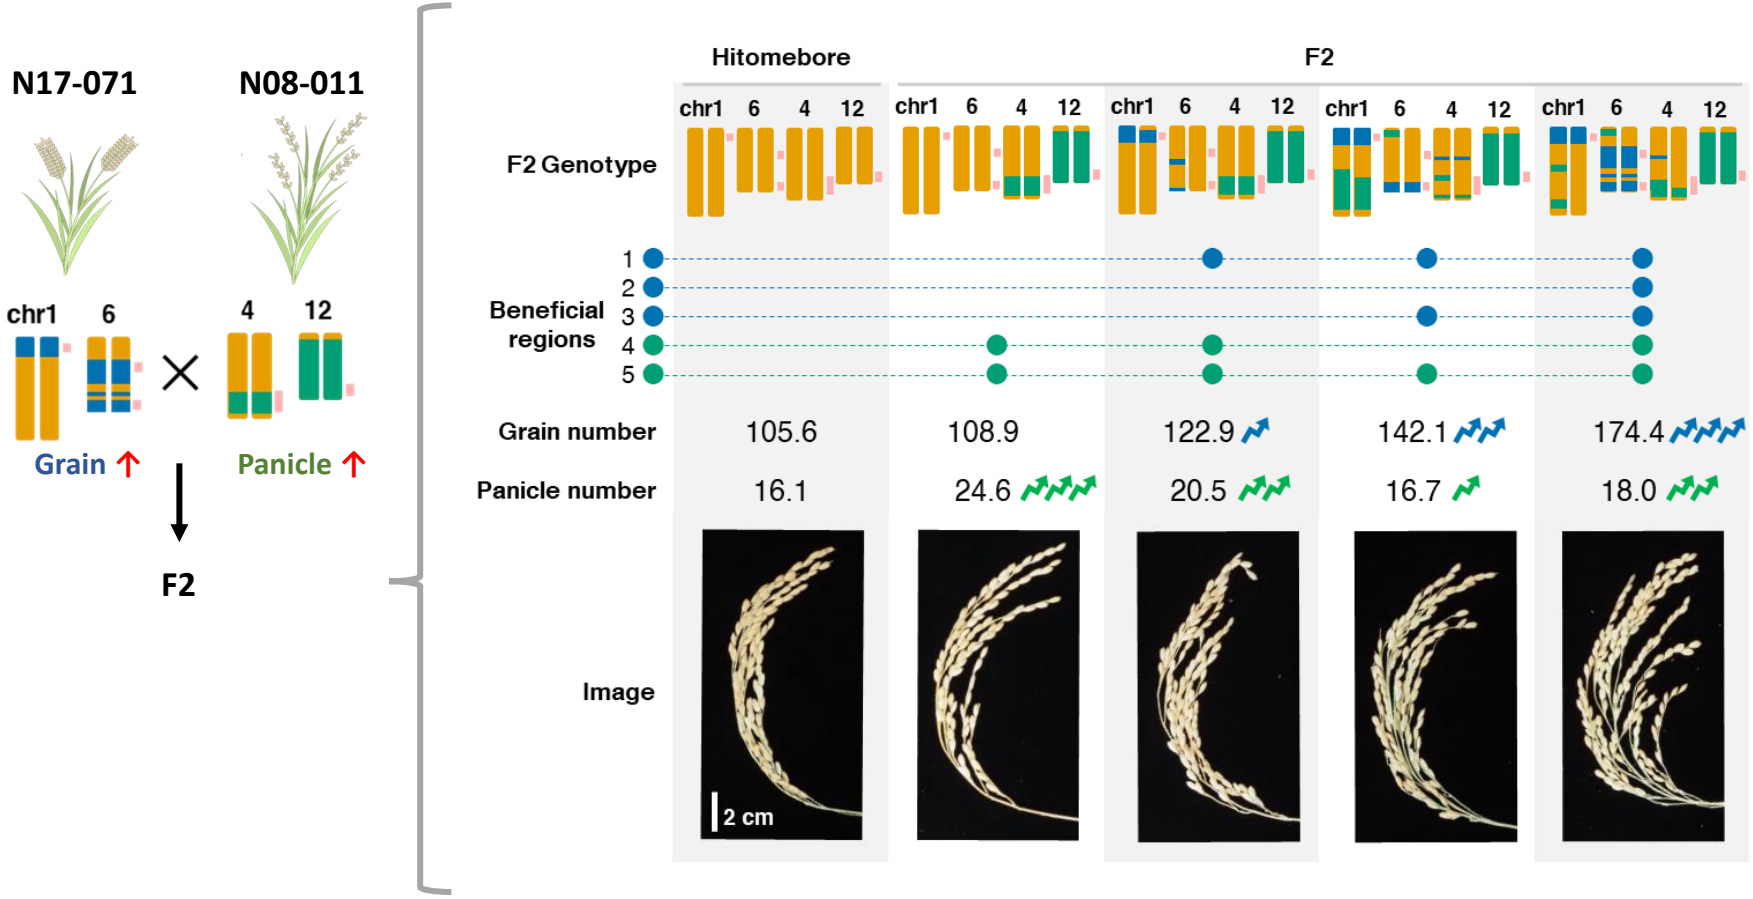


ゲノム領域	変異	籾数	穂数	籾サイズ
chr01: 3~ 4mbp	KALUHEENATIに	↑ ↑ ↑	↓ ↓ ↓	↓ ↓
chr03:12~13mbp	TUPA121-3に	-	-	↑ ↑
chr06: 8~9mbp	C8005に	↓	↑ ↑ ↑	-
…	…	…	…	…

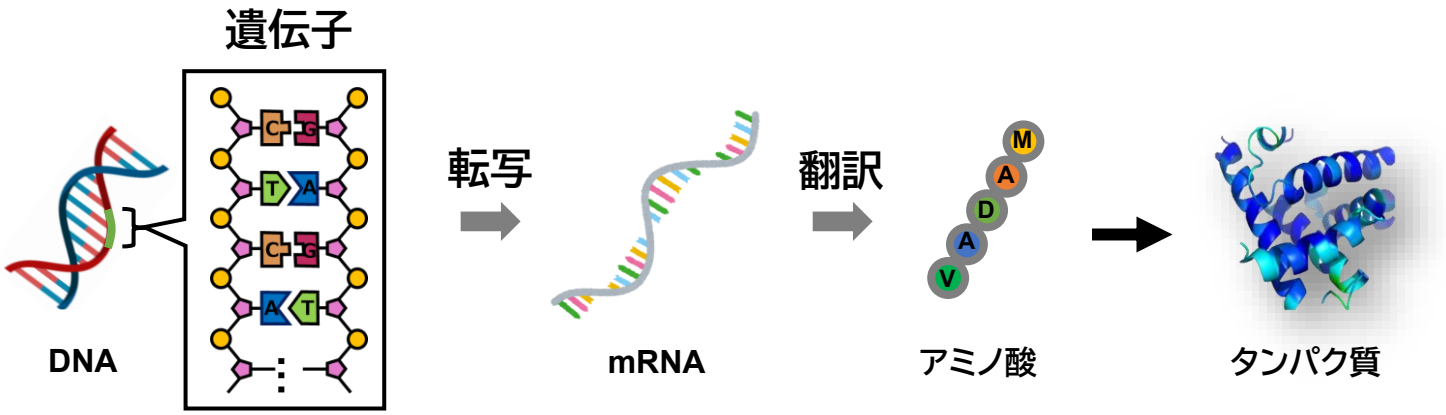
理想の形質を作っていく



穂数と籾数を両者向上させたイネ系統の作出に成功



本講義で扱う解析について



- 配列を読む
- 変異を探す
- 集団データ解析
- 発現量を見る
- 制御関係を探る
- 遺伝子を探す
- 立体構造の予測
- 構造ドメイン予測

来週以降の実習について

- 次回からノートPCを持参してください。
- Googleアカウントを作成しておいてください(既にある人はOKです)。